PROYECTO: ANALÍTICA DE BIG DATA PARA LA SEGURIDAD Y MOVILIDAD EN NUEVA YORK

PROCESAMIENTO DE DATOS A GRAN ESCALA



AUTORES

Martín Sarmiento Galeano

Mateo Jaramillo Londoño

Wilson Muñoz Torres

Presentado a: Felipe Cuervo Perez

Entrega final. Fecha de entrega: 12/10/2026

Resumen

Este documento presenta el proyecto de analítica desarrollado para el estado de Nueva York con el fin de orientar un plan de acción sobre dos indicadores: los arrestos y los accidentes viales. Siguiendo la metodología CRISP-DM, se integraron nueve conjuntos de datos públicos de NYC Open Data y una tabla de población obtenida mediante web scraping, que suman cerca de 13 millones de registros, y se procesaron en un clúster propio de Apache Spark con almacenamiento HDFS montado sobre tres máquinas virtuales.

La primera parte (numerales 1 a 8) corresponde al entendimiento del negocio y de los datos. La segunda (numerales 9 a 14) completa la preparación, responde las ocho preguntas de negocio y aplica modelos de aprendizaje de máquina con MLlib. Entre los resultados principales se encuentra que la tasa anual de arrestos va de 3.334 por cada 100.000 habitantes en el Bronx a 1.908 en Staten Island; que el 34,2% de los choques deja heridos o muertos, proporción que supera el 82% cuando participa una bicicleta o un vehículo de micromovilidad eléctrica; y que siete de los 55 barrios de la ciudad se ubican simultáneamente en la cuarta parte más alta de ambos indicadores.

Un modelo Random Forest distingue los choques con víctimas de los demás con un área bajo la curva ROC de 0,786, frente a 0,721 de la regresión logística usada como referencia y 0,785 de una red neuronal entrenada como bono. Un modelo K-Means agrupa los barrios en cuatro perfiles que permiten diferenciar el tipo de intervención. El documento cierra con conclusiones y recomendaciones para priorizar dónde, cuándo y sobre qué actuar.

1. Entendimiento del negocio

Nueva York es la ciudad más poblada de Estados Unidos, con 8,48 millones de habitantes según las estimaciones más recientes de la Oficina del Censo (New York City Department of City Planning, 2025), y el centro de la mayor economía metropolitana del país, con un producto interno bruto de 2,3 billones de dólares en 2023 (U.S. Bureau of Economic Analysis, s. f.). Esa magnitud económica convive, sin embargo, con desigualdades marcadas: la tasa ampliada de subutilización laboral (U-6) llegó al 9,4% en 2025 (U.S. Bureau of Labor Statistics, 2025), y la pobreza, medida por Robin Hood y la Universidad de Columbia, pasó del 18% en 2021 al 23% en 2022 (Robin Hood & Columbia University, 2024). Con los datos oficiales de pobreza de la ciudad correspondientes a 2018, la tasa por distrito (borough) va del 15,1% en Manhattan al 27,1% en el Bronx.

En seguridad vial, la ciudad implementa desde 2014 la estrategia Vision Zero, orientada a eliminar las muertes en las vías; en 2025 se registraron 205 muertes, la cifra más baja desde que existe registro (New York City Department of Transportation, 2026), aunque uno de cada

tres choques reportados continúa dejando al menos una persona herida o fallecida. En seguridad ciudadana, los arrestos del Departamento de Policía de Nueva York (NYPD) crecieron de forma sostenida desde 2021 y alcanzaron su máximo en 2025, con 278.953 casos.

Cabe aclarar que los arrestos son un indicador de la actividad policial y no una medida directa de la criminalidad; un incremento puede reflejar más delitos, pero también una mayor presencia u operativos de la policía. Por esta razón, en el proyecto los arrestos se interpretan como un indicador de intervención del Estado y se analizan junto con variables de contexto social (pobreza y nivel educativo), sin establecer relaciones de causalidad entre ellas.

Con este panorama, el objetivo de negocio de la consultoría es identificar en qué zonas de la ciudad se concentran los arrestos y los accidentes viales graves en relación con su población, cómo esa concentración se asocia con la pobreza y el nivel educativo de cada distrito, y qué circunstancias de cada choque (causas, vehículos involucrados y franja horaria) elevan el riesgo de que existan heridos, para recomendar al gobierno dónde y cuándo priorizar sus intervenciones sociales, de seguridad vial y de control.

2. Selección de los datos a utilizar

Todas las fuentes principales son públicas y provienen de NYC Open Data, el portal de datos abiertos de la alcaldía de Nueva York, que identifica cada conjunto con un código de ocho caracteres. La selección responde directamente al objetivo de negocio: dos fuentes miden los fenómenos de interés (arrestos y choques), una aporta el detalle de los vehículos involucrados en los choques, y dos permiten caracterizar el contexto social y educativo de cada distrito (pobreza y resultados del SAT); una séptima fuente, los límites de los barrios estadísticos (PUMA), permite ubicar espacialmente los eventos.

Tabla 1
Fuentes de datos seleccionadas

Fuente (identificador)	Contenido	Justificación
Arrestos históricos del NYPD (8h9b-rp9u)	Un registro por arresto desde 2006, con fecha, tipo y gravedad del delito, distrito, coordenadas, edad, sexo y raza.	Primer indicador del caso de negocio.
Arrestos del año en curso (uip8-fykc)	Arrestos de enero a junio de 2026, con las mismas columnas.	Completa el periodo de análisis hasta 2026.
Choques de tránsito (h9gi-nx95)	Un registro por choque: fecha, hora, distrito, coordenadas, heridos y muertos por tipo de víctima, causas y vehículos.	Segundo indicador del caso; permite medir la gravedad.
Vehículos en choques (bm4k-52h4)	Un registro por vehículo involucrado: tipo, año, maniobra y datos del conductor.	Detalle adicional para el modelo de gravedad.

NYCgov Poverty Measure, 2018 (cts7-vksw)	Microdatos de la encuesta ACS ampliada por la alcaldía: pobreza, ingreso, educación y distrito, con el peso de cada persona.	Única fuente oficial de pobreza y educación por persona.
Resultados del SAT, 2012 (f9bf-2cp4)	Puntaje promedio por colegio en el examen de admisión universitaria.	Indicador del contexto educativo.
Límites de las PUMA, 2010 (k2r4-n9ax)	Contorno geográfico de los 55 barrios estadísticos de la ciudad.	Permite ubicar cada arresto y cada choque en su barrio.

Nota. Todas las fuentes provienen de NYC Open Data (data.cityofnewyork.us).

El periodo de análisis abarca de 2019 a 2025, más el primer semestre de 2026, para observar el comportamiento previo a la pandemia y disponer del dato más reciente. Se emplean dos niveles geográficos: el distrito (cinco boroughs), en el que se cruzan todas las fuentes, y el barrio o PUMA (55 zonas), en el que se ubican los arrestos y los choques mediante un cruce espacial de sus coordenadas.

Dos fuentes inicialmente contempladas se descartaron: la población por barrio, disponible solo mediante extracción automatizada de una página que bloquea este tipo de acceso, y el clima diario, que se habría obtenido de una interfaz de programación externa. En cambio, la población oficial de cada distrito sí se obtuvo mediante web scraping de otra página del Departamento de Salud del estado, como se describe en la sección 8.

3. Colección y descripción de los datos

3.1 Infraestructura de procesamiento

El volumen del proyecto (cerca de 13 millones de registros y 2,5 gigabytes) excede la capacidad de un único computador, por lo que los datos se procesaron en un clúster distribuido: tres máquinas virtuales de la universidad, cada una con sistema operativo Rocky Linux 9, cuatro núcleos de procesador y 15,7 GB de memoria RAM. Sobre ellas se instalaron Apache Spark 4.1.3, en modo standalone, como motor de procesamiento, y Apache Hadoop 3.5.0 (HDFS) como sistema de almacenamiento distribuido, con replicación de dos copias por bloque (The Apache Software Foundation, s. f.-a, s. f.-b).

Tabla 2
Distribución de funciones en el clúster

Máquina	Funciones asignadas	Recursos para el cálculo
VM1	Master, worker, driver, NameNode y DataNode de HDFS	2 núcleos, 5 GB
VM2	Worker, DataNode	3 núcleos, 8 GB

VM3	Worker, DataNode	3 núcleos, 8 GB
Total	8 executors de 1 núcleo y 2,5 GB cada uno	8 núcleos, 21 GB

La verificación del clúster confirmó su correcto funcionamiento: los ocho executors se conectaron sin inconvenientes, un trabajo de prueba dividido en 200 tareas se distribuyó de forma proporcional a los recursos de cada máquina, y la escritura y lectura de diez millones de filas en HDFS tomó 10,1 y 6,2 segundos, respectivamente. El diseño completo de la infraestructura, junto con el registro de incidencias durante su instalación, se documenta en el repositorio del proyecto.

Las siete fuentes se descargaron íntegramente desde la API de NYC Open Data mediante un script reproducible que registra, para cada archivo, su tamaño, número de líneas y huella criptográfica SHA-256 antes de cargarlo a HDFS. Los archivos, originalmente en formato CSV, se convirtieron a Parquet (formato columnar y comprimido) con una reducción de tamaño de entre 2,6 y 5,2 veces, y se organizaron en capas sucesivas de refinamiento (cruda, bronce, plata y oro), de modo que los datos originales nunca se modifican y el proceso puede rehacerse en cualquier momento. La conversión completa de los 2,5 GB tomó 3,7 minutos.

3.2 Descripción de las fuentes

El significado de cada atributo se obtuvo de los metadatos oficiales publicados por cada entidad en NYC Open Data y, para la encuesta de pobreza, de su diccionario técnico (New York City Mayor's Office for Economic Opportunity, s. f.). La tabla 3 resume el tipo de dato predominante y algunos atributos representativos de cada fuente.

Tabla 3
Tipo y contenido de las principales fuentes

Fuente	Registros	Tipo de datos	Atributos representativos
Arrestos (histórico y año en curso)	6.406.848	Categóricos y de fecha	Fecha, tipo y gravedad del delito, distrito, edad, sexo, raza, coordenadas
Choques de tránsito	2.269.187	Categóricos, numéricos y de fecha	Fecha, hora, distrito, heridos/muertos por tipo de víctima, causas, vehículos
Vehículos en choques	4.551.002	Categóricos	Tipo y año del vehículo, maniobra, punto de impacto, causas
Pobreza (NYCgov)	68.273	Numéricos y	Distrito, condición de pobreza, ingreso, nivel educativo, peso

		categóricos	muestral
SAT (2012)	478	Numéricos	Puntaje promedio en lectura, matemáticas y escritura por colegio
PUMA (2010)	55	Geoespacial	Código, área y contorno de cada barrio estadístico

La tabla de arrestos identifica cada registro mediante la llave ARREST_KEY y clasifica el delito según su gravedad legal (felonía, delito menor o infracción). La tabla de choques, identificada por COLLISION_ID, reporta únicamente los incidentes con heridos, muertos o daños superiores a 1.000 dólares, y se enlaza con la tabla de vehículos mediante ese mismo identificador. En la encuesta de pobreza, cada fila corresponde a una persona (identificada por la combinación del hogar y su orden dentro de este) y lleva asociado un peso muestral. Como la encuesta no consulta a toda la población, las cifras agregadas por persona, como la tasa de pobreza por distrito, deben calcularse ponderando por este peso y no mediante un conteo simple de filas. La suma de los pesos permite además estimar la población de cada distrito, con un total aproximado de 8,2 millones de habitantes. El perfil detallado de cada columna, con el porcentaje de valores presentes y ejemplos representativos, se documenta en el repositorio del proyecto.

4. Exploración de los datos

El análisis exploratorio se realizó sobre la capa plata del clúster. Las comparaciones entre distritos se expresan en tasas por cada 100.000 habitantes y no en conteos absolutos, con el fin de no confundir el tamaño de la población con la intensidad del fenómeno. A continuación se resumen los ocho hallazgos principales del análisis.

En primer lugar, los arrestos cayeron en 2020 (año de la pandemia, con 140.413 casos) y aumentaron de forma sostenida hasta 278.953 en 2025, un 30% más que en 2019. (Ver Figura 1). Por otro lado, al comparar los distritos por tasa poblacional (Ver Figura 2), el Bronx (3.437 arrestos por 100.000 habitantes al año) y Manhattan (3.233) casi duplican a Queens y Staten Island (alrededor de 1.950); en el caso de Manhattan, la elevada tasa podría estar influida por su población flotante de trabajadores y visitantes, hipótesis que se profundizará en la entrega final. Además, entre el 40% y el 45% de los arrestos corresponden a felonías y entre el 52% y el 59% a delitos menores, con Brooklyn como el distrito de mayor proporción de felonías; los delitos más frecuentes son la agresión de menor gravedad (15,2%) y el hurto menor (9,9%). (Ver figura 3).

Figura 1

Arrestos por año, de 2019 al primer semestre del 2026.

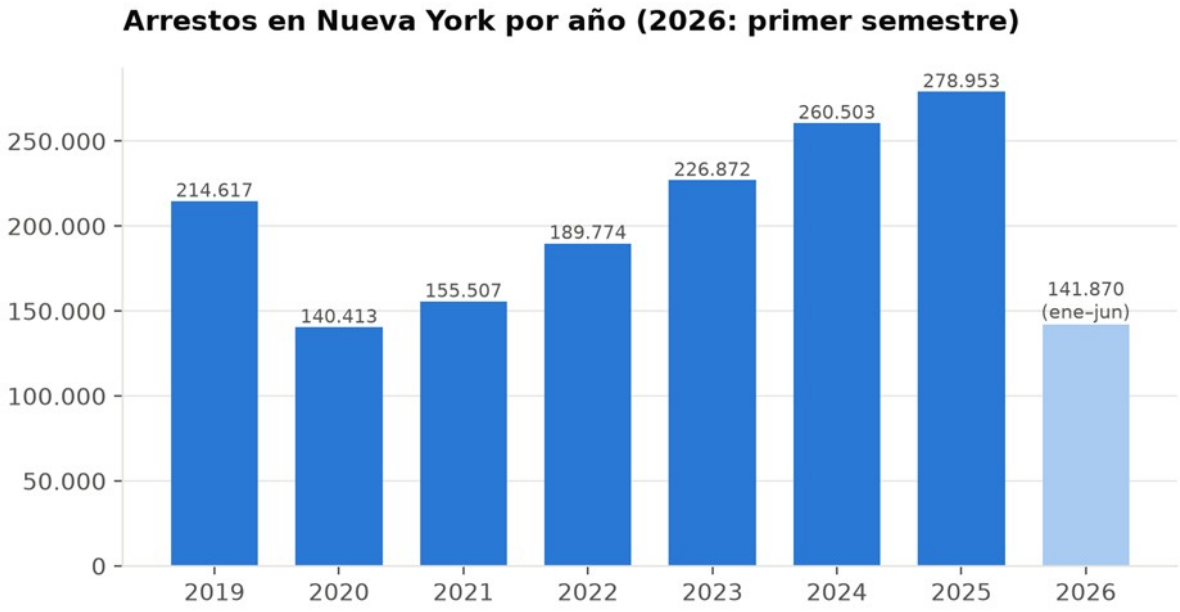


Figura 2

Arrestos al año por cada 100.000 habitantes, promedio 2019–2025.

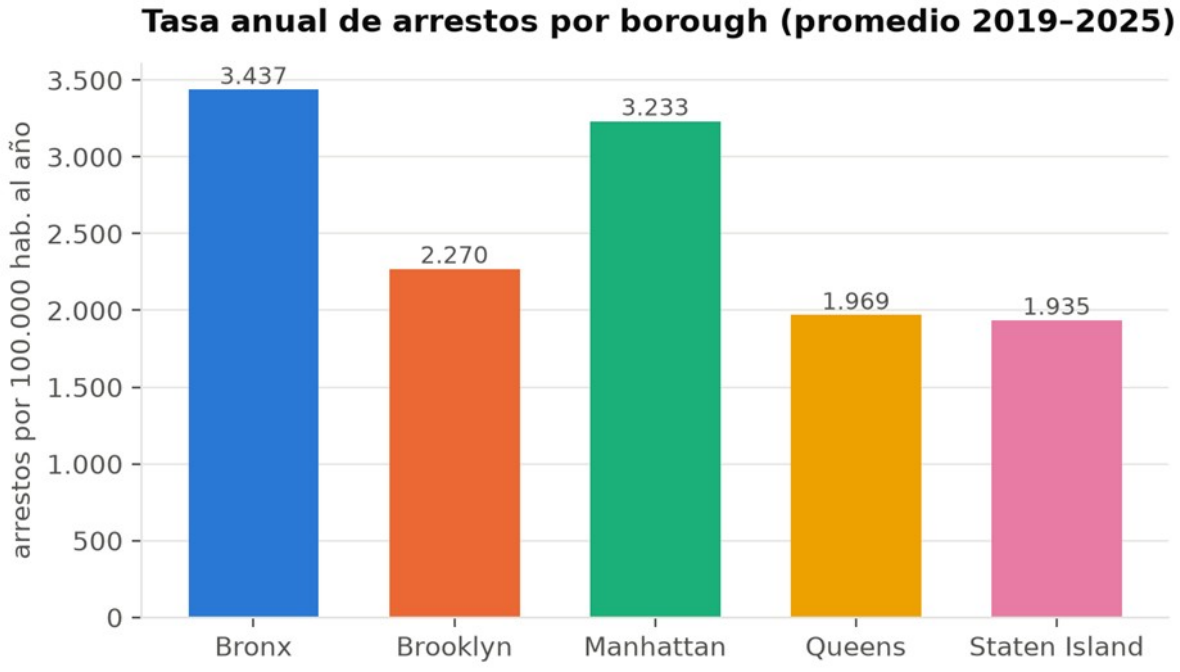
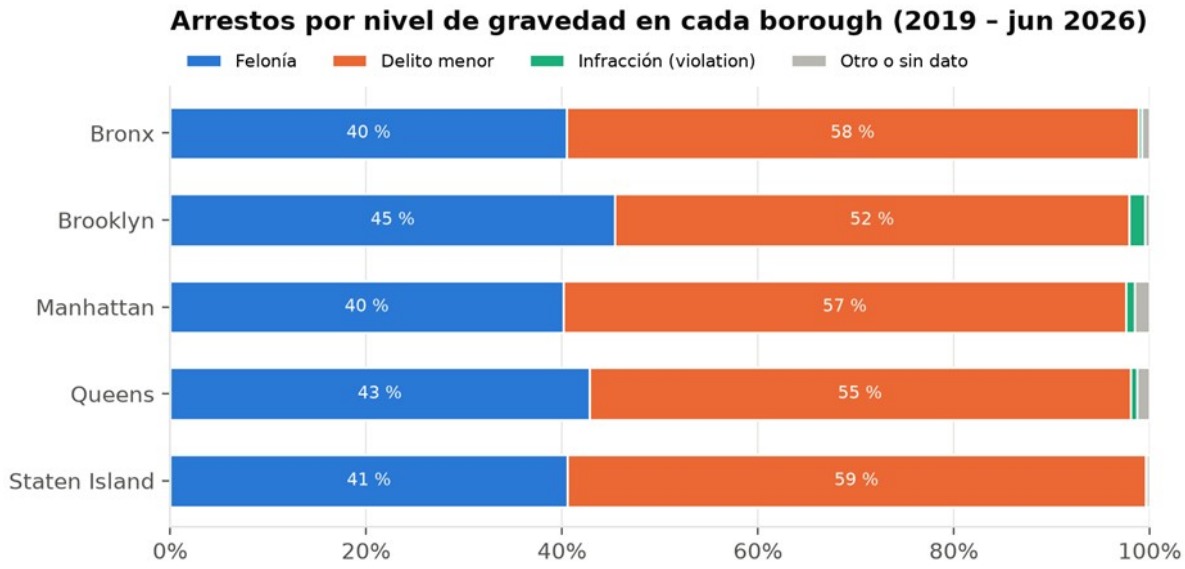


Figura 3

Composición de los arrestos de cada borough según la gravedad legal.



El total de choques se redujo un 60% entre 2019 y 2025, aunque los choques con heridos o muertos disminuyeron en menor proporción, por lo que su participación relativa aumentó; la causa de esta caída aún no se ha establecido con certeza. (Ver figura 4). También, en el mapa de calor de la Figura 5 se aprecia que los choques graves se concentran entre semana, en las horas de la tarde (2:00 p. m. a 6:00 p. m.), mientras que los fines de semana se distribuyen más hacia la noche y la madrugada. Este patrón resulta relevante para orientar el momento de las intervenciones viales.

Y otro aspecto bastante interesante es que entre el 31,7% (Manhattan) y el 35,5% (Brooklyn) de los choques dejan al menos una persona herida o fallecida, y la distracción del conductor es, por amplio margen, la causa más frecuente (211.288 casos), aunque en el 24,6% de los registros la causa no se especifica. (Ver Figura 6 y 7).

Figura 4

Choques por mes: total y choques con heridos o muertos.

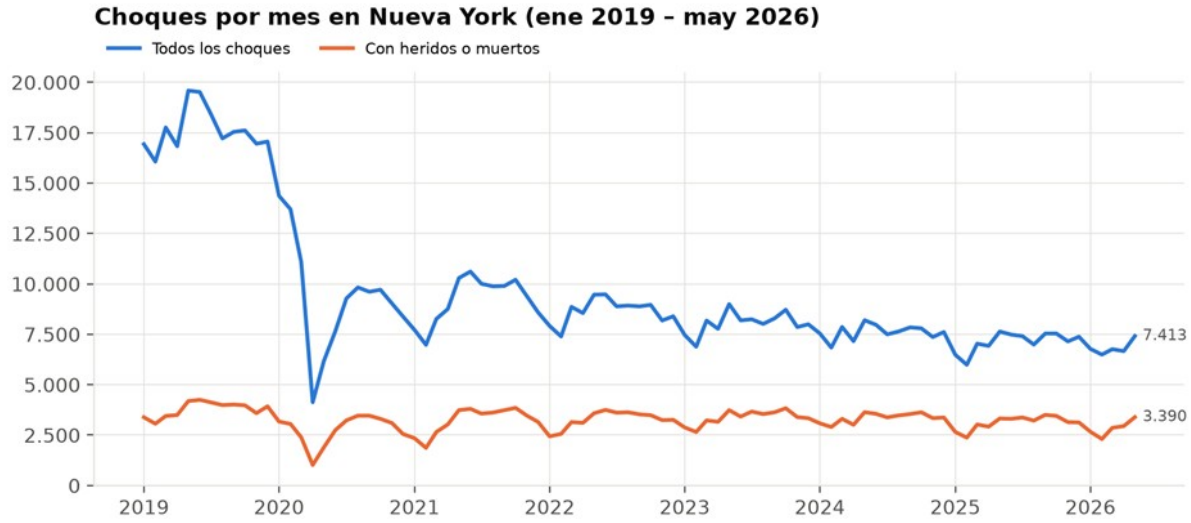


Figura 5

Choques con heridos o muertos por hora del día y día de la semana.

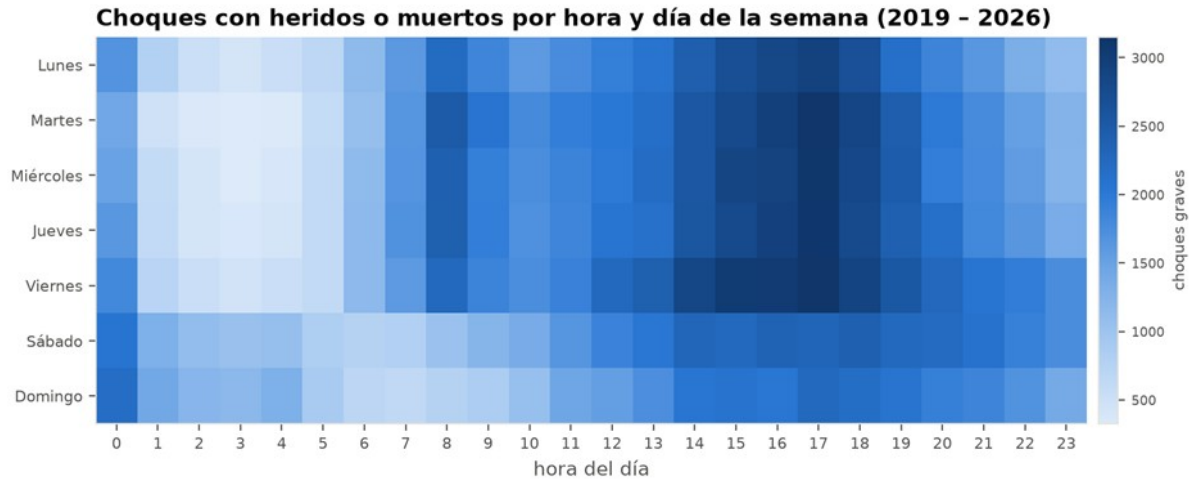


Figura 6
Porcentaje de choques con heridos o muertos en cada borough.

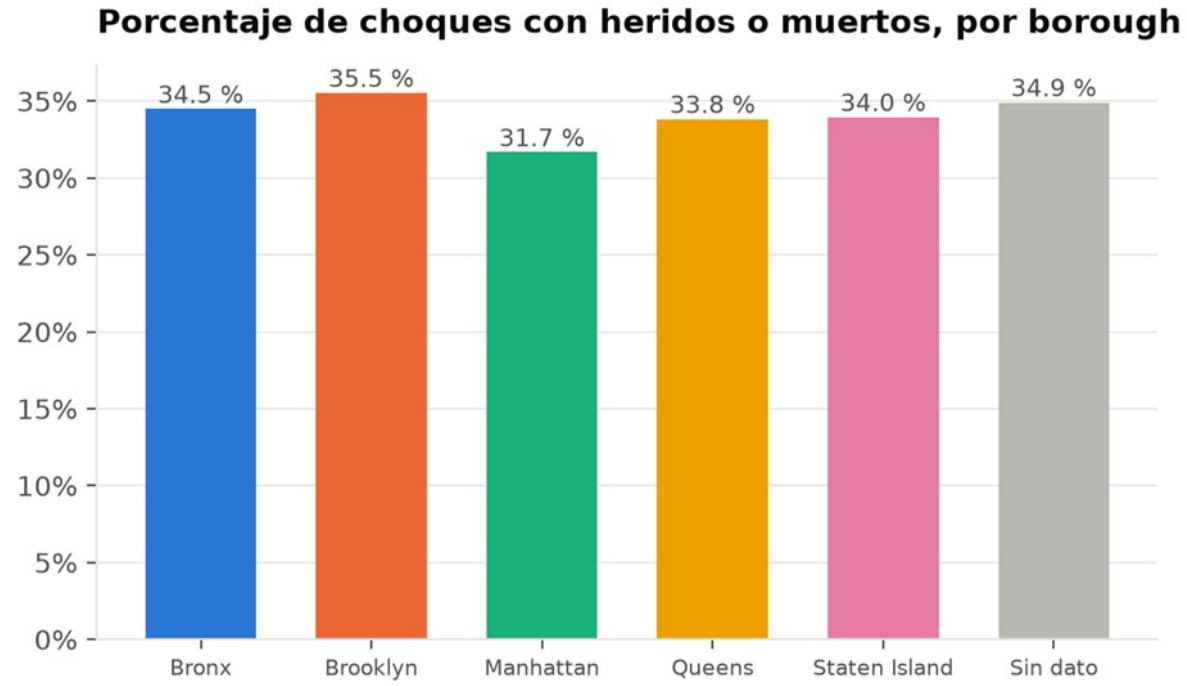
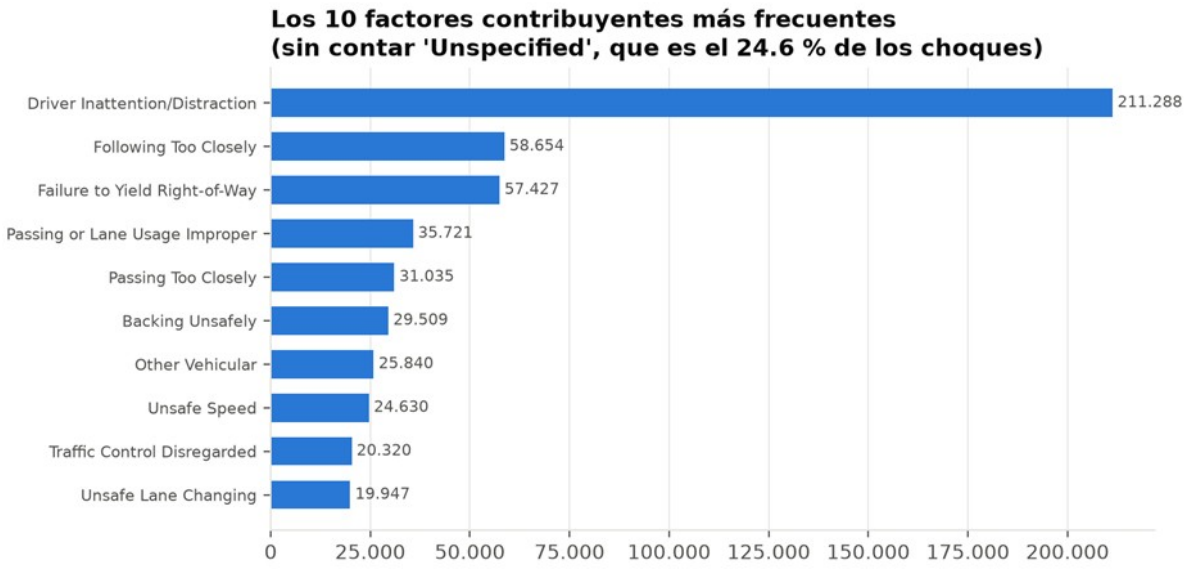


Figura 7
Los 10 factores contribuyentes más frecuentes.



En séptimo lugar, la tasa de pobreza por distrito va del 15,1% en Manhattan al 27,1% en el Bronx (Ver Figura 8), mientras que la proporción de adultos con título universitario va del 61% en Manhattan al 20% en el Bronx. (Ver Figura 9). Por último, al integrar los indicadores por distrito (tabla 4), el Bronx concentra simultáneamente la mayor pobreza, el menor nivel educativo y la mayor tasa de arrestos, mientras que Brooklyn presenta la mayor tasa de choques graves; esta coincidencia entre indicadores no implica una relación causal y se examinará con mayor detalle en la entrega final.

Figura 8

Tasa de pobreza por borough en 2018 (medida oficial de la ciudad), calculada con los pesos de la encuesta.

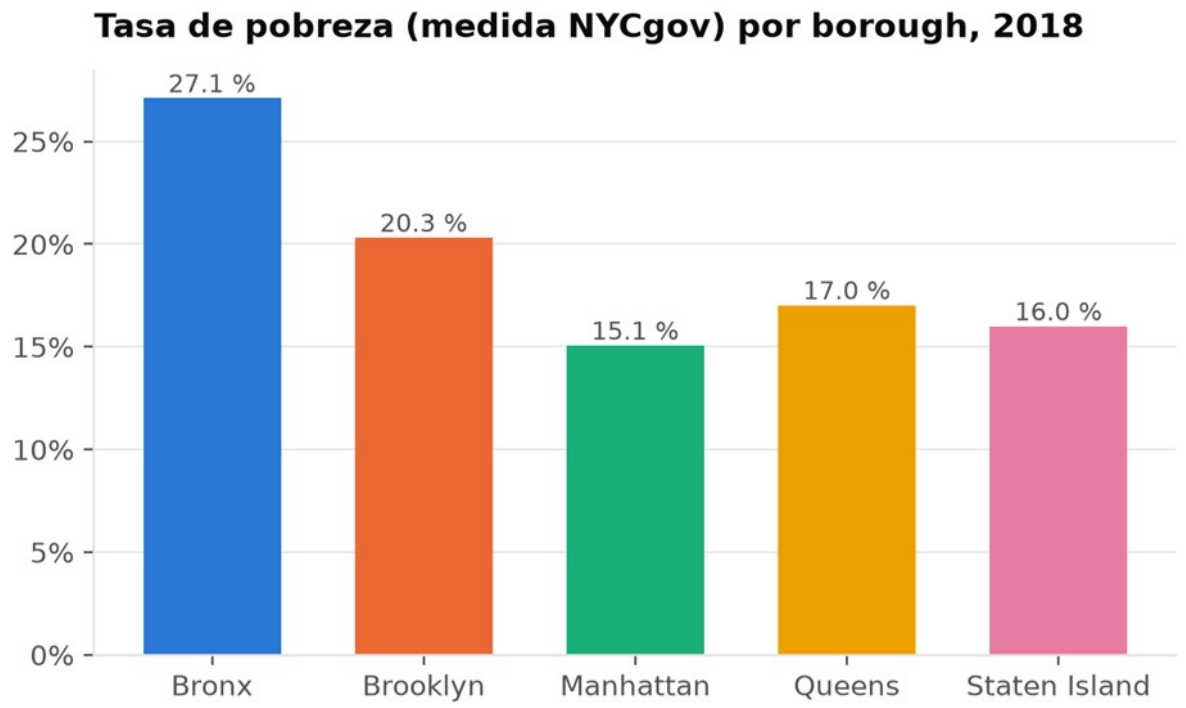


Figura 9
Nivel educativo de los adultos por borough, 2018.

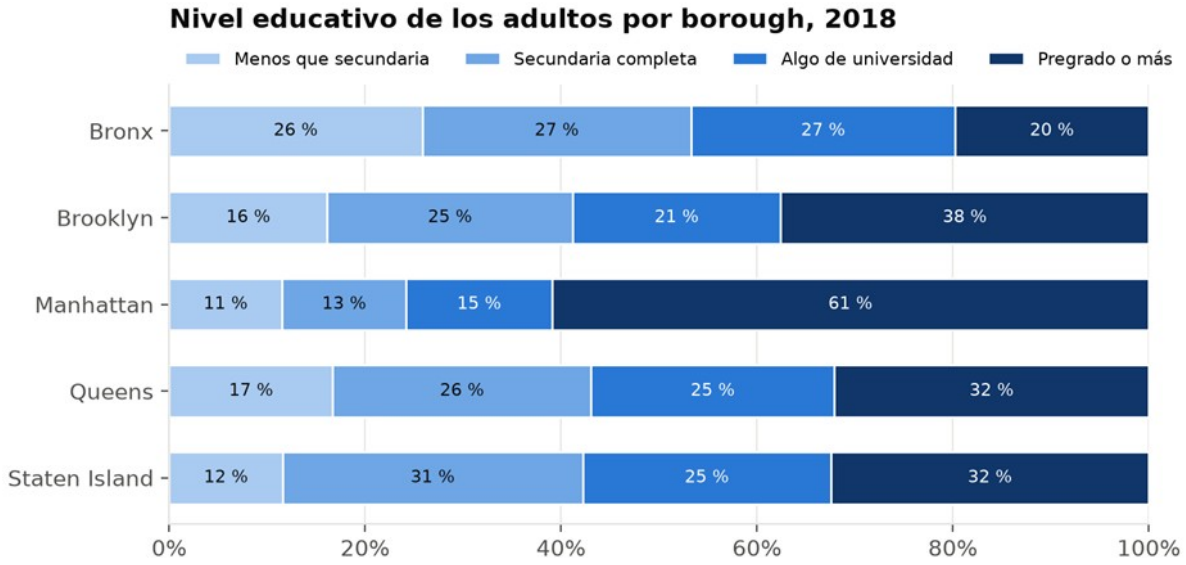


Tabla 4
Indicadores por distrito (borough)

Distrito	Población	Pobreza	Con pregrado o más	SAT total	Arrestos / 100 mil hab.	Choques graves / 100 mil hab.
Bronx	1.389.245	27,1 %	19,8 %	1.145	3.437	449
Brooklyn	2.540.638	20,3 %	37,6 %	1.167	2.270	491

Manhattan	1.568.288	15,1 %	60,9 %	1.260	3.233	381
Queens	2.250.749	17,0 %	32,1 %	1.275	1.969	464
Staten Island	469.393	16,0 %	32,5 %	1.359	1.935	360

Nota. Las tasas corresponden al promedio anual de 2019 a 2025. Población, pobreza y educación con datos de la encuesta de 2018, ponderados. Puntaje del SAT de 2012. Un choque se considera grave si registra al menos un herido o un fallecido.

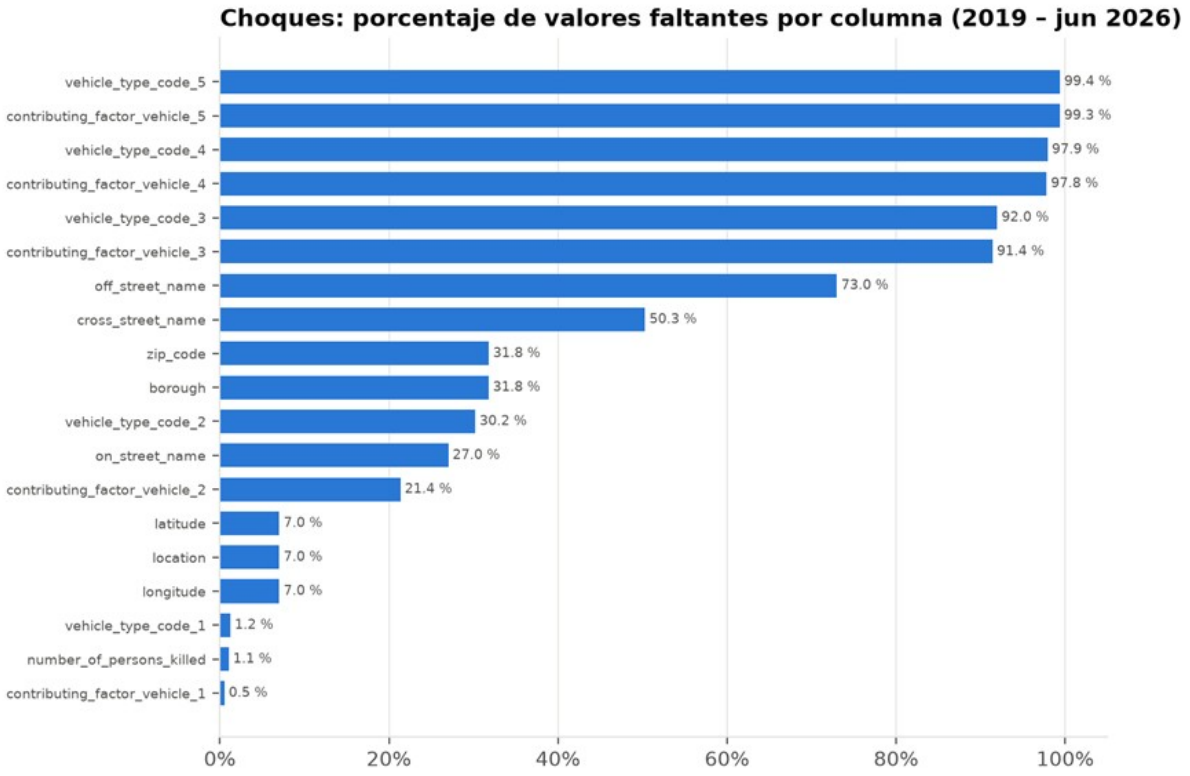
5. Reporte de calidad de los datos

La evaluación de calidad consideró tanto los valores faltantes explícitos (casillas vacías o nulas) (Ver Figura 10) como los valores faltantes disfrazados, es decir, entradas que contienen un valor pero no aportan información real, como las coordenadas (0, 0) (ubicadas en el océano) o las categorías Unspecified y Unknown. La tabla 5 resume los resultados para las fuentes evaluadas dentro del periodo de estudio.

Tabla 5
Resumen de valores faltantes por fuente

Fuente	Filas evaluadas	Columnas con faltantes	Casillas faltantes	Columna más incompleta
Arrestos	1.608.509	7 de 18	0,05 %	Gravedad legal (0,70 %)
Choques	848.742	20 de 29	29,90 %	Tipo del 5.º vehículo (99,38 %)
Vehículos	1.715.328	19 de 25	22,83 %	Modelo del vehículo (99,45 %)
Pobreza	68.273	8 de 61	3,23 %	Dominio del inglés (55,01 %)
SAT	478	0 de 6	0,00 %	Ninguna (57 colegios con dato oculto)

Figura 10
Porcentaje de valores faltantes en cada columna de la tabla de choques.



Entre los hallazgos más relevantes se destaca la ausencia del distrito en el 31,8% de los choques, el problema de mayor impacto sobre el análisis por zona, dado que sin distrito casi un tercio de los registros quedaría excluido; de estos, 221.658 casos cuentan con coordenadas válidas y son recuperables mediante un cruce espacial. También se identificó que la columna de grupo de edad de los arrestos de 2025 presenta el valor nulo en el 52,8% de esos registros (frente al 0% en los demás años), lo que indica un cambio en el proceso de captura del dato y no un faltante aleatorio; por esta razón, 2025 se excluirá de las comparaciones por edad. Asimismo, la causa del choque no se especifica en el 24,6% de los casos, y columnas como el tercer al quinto vehículo involucrado presentan altos porcentajes de vacíos que corresponden a la naturaleza del dato (la mayoría de los choques involucra uno o dos vehículos) y no a errores de captura. En la encuesta de pobreza, los faltantes en variables como nivel educativo o estado civil corresponden a preguntas que no se formulan a ciertos rangos de edad.

Con base en estos hallazgos se definió un tratamiento diferenciado por problema: el distrito faltante en los choques se recupera mediante cruce espacial; las coordenadas en (0, 0) y los valores fuera de rango se dejan vacíos sin eliminar el registro; los códigos de gravedad no documentados se agrupan en una categoría explícita; y ningún valor se imputa arbitrariamente cuando ello pudiera introducir sesgos, como ocurre con la raza de la persona arrestada o la causa no especificada del choque, cuyo tratamiento definitivo se abordará posteriormente.

6. Planteamiento de preguntas de negocio

1. ¿Cuál es la tasa de arrestos por cada 100.000 habitantes en cada distrito y en cada barrio, y cómo ha cambiado entre 2019 y 2026?
2. ¿Los distritos con mayor tasa de pobreza presentan también una mayor tasa de arrestos por habitante, y esta relación se mantiene al separar felonías de delitos menores?
3. ¿Qué tipos de delito predominan en los distritos con mayor pobreza frente a los de menor pobreza?
4. ¿Cuáles son los diez barrios con mayor tasa de choques con heridos o muertos?
5. ¿Qué causas del choque y qué tipos de vehículo se asocian con una mayor proporción de choques con heridos o muertos?
6. ¿En qué horas y días se concentran los choques graves, y este patrón es homogéneo entre distritos?
7. ¿Qué barrios combinan una alta tasa de arrestos con una alta tasa de choques graves y deberían priorizarse?
8. ¿Los arrestos por infracciones de tránsito y conducción bajo estado de embriaguez se concentran en las zonas con mayor accidentalidad grave?

7. Filtros, limpieza y transformación inicial

La capa plata del proyecto se construyó mediante los siguientes procedimientos, cuyo efecto se midió en cada caso: unificación de los arrestos históricos con los del año en curso; filtro del periodo de estudio (arrestos hasta el 30 de junio de 2026, y choques y vehículos hasta el 31 de mayo de 2026, último mes con datos completos); asignación del tipo de dato correcto a cada columna; conversión a valores vacíos de los datos imposibles, como coordenadas fuera de Nueva York o años de fabricación inválidos; traducción de los códigos oficiales a su descripción; y un cruce espacial que ubica cada arresto y cada choque dentro de su barrio a partir de sus coordenadas.

Tabla 6
Registros antes y después del filtro de periodo

Fuente	Registros originales	En el periodo de estudio
Arrestos	6.406.848	1.608.509
Choques	2.269.187	846.420
Vehículos	4.551.002	1.710.836

No se encontraron registros duplicados en ninguna de las tres fuentes. El cruce espacial permitió recuperar el distrito de 219.488 choques que no lo tenían registrado (25,9% del total) a partir de sus coordenadas; validado contra los registros que sí contaban con ambos datos, la coincidencia entre el distrito original y el obtenido por cruce espacial alcanzó el 99,88% en choques y el 99,7% en arrestos, lo que respalda la confiabilidad del método. Como resultado, el

94,1% de los choques cuenta hoy con distrito asignado, frente al 68,2% con que se contaba originalmente.

Para efectos del trabajo futuro, queda pendiente completar los conteos de víctimas, unificar las categorías de tipo de vehículo y de causa del choque, definir el tratamiento de la edad en los arrestos de 2025, y construir la capa oro con los resúmenes que alimentarán el modelo de clasificación y la segmentación de barrios.

8. Bono: extracción de datos web (web scraping)

Como complemento, la población oficial de cada distrito se obtuvo mediante web scraping, es decir, la extracción automatizada de datos a partir del código HTML de una página web, técnica que se emplea cuando la información se publica únicamente para ser consultada en el navegador, sin archivo descargable ni API. La fuente es la tabla 2 de las estadísticas vitales del estado de Nueva York de 2018 (New York State Department of Health, 2020), que reporta para los 62 condados del estado la población estimada de 2018, la del censo de 2010, el área y la densidad; en Nueva York cada distrito corresponde a un condado (Kings equivale a Brooklyn, New York a Manhattan y Richmond a Staten Island). A diferencia de la encuesta de pobreza, que excluye a quienes residen en alojamientos colectivos, esta cifra incluye a toda la población residente, por lo que constituye un mejor denominador para las tasas por habitante.

El proceso se automatizó en el notebook 06_bono_scraping_poblacion. Se llevó a cabo un registro de la huella SHA-256 del archivo y copia en la capa cruda de HDFS, recorrido de la tabla fila por fila con la librería BeautifulSoup (distinguiendo los títulos de sección de las filas de datos), limpieza de los valores numéricos y validación. Esta última se apoyó en los totales publicados por la propia tabla, así que se verificó que existieran 62 condados, que los cinco distritos sumaran exactamente el total de la ciudad en 2018 y en 2010, que los 62 condados sumaran el total del estado y que la densidad publicada coincidiera con la población dividida por el área, con la misma precisión de dos decimales de la fuente. Las siete validaciones se cumplieron, y la tabla 7 resume los datos obtenidos para los cinco distritos.

Tabla 7
Población oficial, área y densidad por distrito, 2018

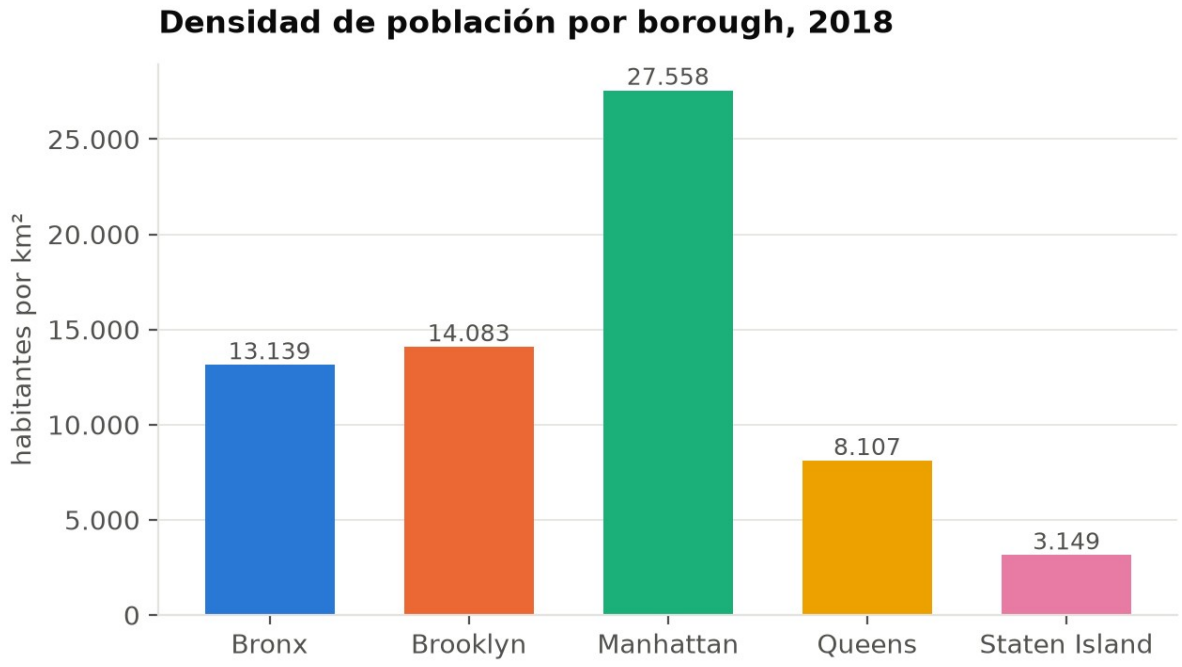
Distrito (condado)	Población 2018	Población 2010	Área (km²)	Habitantes por km²
Bronx (Bronx)	1.432.132	1.385.108	109,0	13.139
Brooklyn (Kings)	2.582.830	2.504.700	183,4	14.083
Manhattan (New York)	1.628.701	1.585.873	59,1	27.558

Queens (Queens)	2.278.906	2.230.722	281,1	8.107
Staten Island (Richmond)	476.179	468.730	151,2	3.149
Nueva York	**8.398.748**	**8.175.133**	**783,9**	**10.715**

Nota. Datos extraídos mediante web scraping de New York State Department of Health (2020). El área se convirtió de millas cuadradas a kilómetros cuadrados (1 mi² = 2,59 km²).

Manhattan alcanza 27.558 habitantes por km², casi el doble que Brooklyn (14.083) y el Bronx (13.139) y cerca de nueve veces la densidad de Staten Island (3.149) (ver Figura 11), un factor relevante para interpretar la accidentalidad, pues una mayor densidad implica más peatones, vehículos y cruces por calle. Por su parte, la población estimada con la encuesta (tabla 4) resulta inferior a la oficial en todos los distritos, entre el 1,2% (Queens) y el 3,7% (Manhattan), con una diferencia total de 180.435 personas (2,1%), compatible con la exclusión de los alojamientos colectivos, aunque los datos disponibles no permiten comprobarlo.

Figura 11
Densidad de población por distrito, 2018 (habitantes por km²).



Fuente: NYS Department of Health, Vital Statistics 2018, Tabla 2 (scraping propio).

Finalmente, se recalcularon las tasas por cada 100.000 habitantes con la población oficial (tabla 8). Las tasas disminuyen entre el 1,3% y el 3,7%, sin que ningún distrito cambie de posición: el Bronx mantiene la mayor tasa de arrestos (3.334) y Brooklyn la mayor tasa de choques graves (483). En consecuencia, los hallazgos de la exploración no dependen de la población utilizada, y se propone emplear la cifra oficial como denominador en la entrega final.

La principal limitación de esta fuente es que reporta los datos por condado, de modo que la población por barrio continúa sin estar disponible.

Tabla 8
Tasas anuales por cada 100.000 habitantes según la población utilizada

Distrito	Arrestos (encuesta)	Arrestos (oficial)	Choques graves (encuesta)	Choques graves (oficial)
Bronx	3.437	3.334	449	436
Brooklyn	2.270	2.233	491	483
Manhattan	3.233	3.113	381	367
Queens	1.969	1.944	464	458
Staten Island	1.935	1.908	360	354

Nota. Promedio anual de 2019 a 2025. Los valores calculados con la población de la encuesta corresponden a los de la tabla 4. Un choque se considera grave si registra al menos un herido o un fallecido.

9. Filtros y transformaciones finales

Esta sección completa la limpieza que quedó planteada en el numeral 7 y construye la capa oro, es decir, el conjunto de tablas agregadas de las que se obtienen las respuestas a las preguntas de negocio y los datos de entrada de los modelos. El procedimiento se encuentra en el notebook 07_capa_oro. Ningún paso elimina registros de la capa plata: los filtros solo definen qué entra en cada tabla agregada, y cada procedimiento se registró junto con su efecto (tabla 9).

La primera transformación resuelve la principal limitación de la primera entrega, la ausencia de población por barrio. Se sumó la población del censo de 2010 de los 195 vecindarios de la ciudad (New York City Open Data, s. f.-g) a los 55 barrios mediante la tabla oficial de equivalencias (New York City Open Data, s. f.-h). El resultado se validó contra una fuente independiente: la población de 2010 por distrito obtenida por web scraping en el numeral 8, con la que coincide exactamente en los cinco distritos. Los vecindarios no residenciales (parques, cementerios y aeropuertos) no pueden asignarse a un único barrio; reúnen 4.609 habitantes, el 0,06% de la ciudad. Para que las tasas por barrio sean comparables con las de distrito, la población de cada barrio se ajustó a 2018 con el factor de crecimiento de su distrito, lo que supone que todos los barrios de un mismo distrito crecieron al mismo ritmo entre 2010 y 2018.

En los arrestos se identificaron los relacionados con el tránsito según el tipo de delito: 122.156 registros, el 7,6% del total, de los cuales 24.251 corresponden a conducción en estado de embriaguez. Respecto a la edad de la persona arrestada, que no viene registrada en el 52,8%

de los arrestos de 2025, se decidió no imputarla, puesto que asignar el grupo más frecuente crearía una distribución de edades artificial para ese año; ninguna pregunta de negocio ni ningún modelo utiliza esta variable.

En los choques se aplicaron cuatro transformaciones. Primero, el total de heridos y de muertos se reconstruyó con el desglose por tipo de víctima cuando venía vacío, tras lo cual 11 choques cambiaron de clasificación de gravedad. Segundo, los 61 textos distintos del factor contribuyente se agruparon en 12 causas; el 25,2% de los choques no especifica la causa y se conserva como una categoría propia, porque imputarla sesgaría justamente la variable que se quiere estudiar. Tercero, los 1.653 textos de tipo de vehículo, que es un campo de escritura libre, se agruparon en diez tipos. Cuarto, se construyó una tabla con una fila por choque que incluye la franja horaria, el número de vehículos y la presencia de motocicletas, bicicletas, vehículos de micromovilidad eléctrica, camiones, buses y taxis. La unidad de análisis es el choque y no el vehículo, para evitar que dos vehículos de un mismo choque queden repartidos entre los datos de entrenamiento y los de prueba del modelo.

Se aplicaron tres filtros. Los promedios anuales se calculan solo con los años completos, de 2019 a 2025, porque el primer semestre de 2026 no es comparable con un año entero. Los análisis por barrio emplean únicamente los registros con coordenadas válidas dentro de alguno de los 55 barrios, y los análisis por distrito, los registros que tienen distrito. Finalmente se verificó que los totales de las tablas agregadas coinciden con los conteos directos sobre la capa plata.

Tabla 9
Filtros y transformaciones aplicados en la preparación final

Tipo	Tabla	Procedimiento	Efecto
Transformación	Población	Población 2010 por vecindario sumada a los 55 barrios y ajustada a 2018 con el factor de su distrito	55 barrios, de 109.327 a 253.742 habitantes
Transformación	Arrestos	Marca de arrestos de tránsito y de embriaguez según el tipo de delito	122.156 de tránsito (7,6%), de ellos 24.251 por embriaguez
Decisión	Arrestos	La edad vacía no se imputa; los análisis por edad excluyen los años con más de 5% sin dato	Los análisis por edad excluyen 2025
Transformación	Choques	Total de heridos y muertos reconstruido con el desglose cuando viene vacío; gravedad recalculada	11 choques cambian de gravedad
Transformación	Choques	61 textos de factor contribuyente agrupados en 12 causas, más «Otra causa» y «Sin especificar»	25,2% sin especificar, 0,0% en «Otra causa»

Tipo	Tabla	Procedimiento	Efecto
Transformación	Vehículos	1.653 textos de tipo de vehículo agrupados en 10 tipos, más «Otro» y «Sin dato»	0,4% en «Otro», 11,0% sin dato
Transformación	Choques	Franja horaria, fin de semana, número de vehículos y presencia de moto, bicicleta, micromovilidad, camión, bus y taxi	Tabla choques_modelo con 846.420 filas, una por choque; 34,2% graves
Filtro	Arrestos	Años completos 2019 a 2025 (para promedios anuales)	1.608.509 → 1.466.639 (91,2%)
Filtro	Arrestos	Con barrio (coordenadas válidas dentro de un barrio)	1.466.639 → 1.466.463 (100,0%)
Filtro	Arrestos	Con distrito	1.466.639 → 1.466.639 (100,0%)
Filtro	Choques	Años completos 2019 a 2025 (para promedios anuales)	846.420 → 812.318 (96,0%)
Filtro	Choques	Con barrio (coordenadas válidas dentro de un barrio)	812.318 → 745.375 (91,8%)
Filtro	Choques	Con distrito	812.318 → 762.987 (93,9%)

Nota. Elaboración propia a partir del notebook 07_capa_oro. En los filtros, el efecto muestra los registros antes y después y el porcentaje que se conserva.

10. Respuestas a las preguntas de negocio

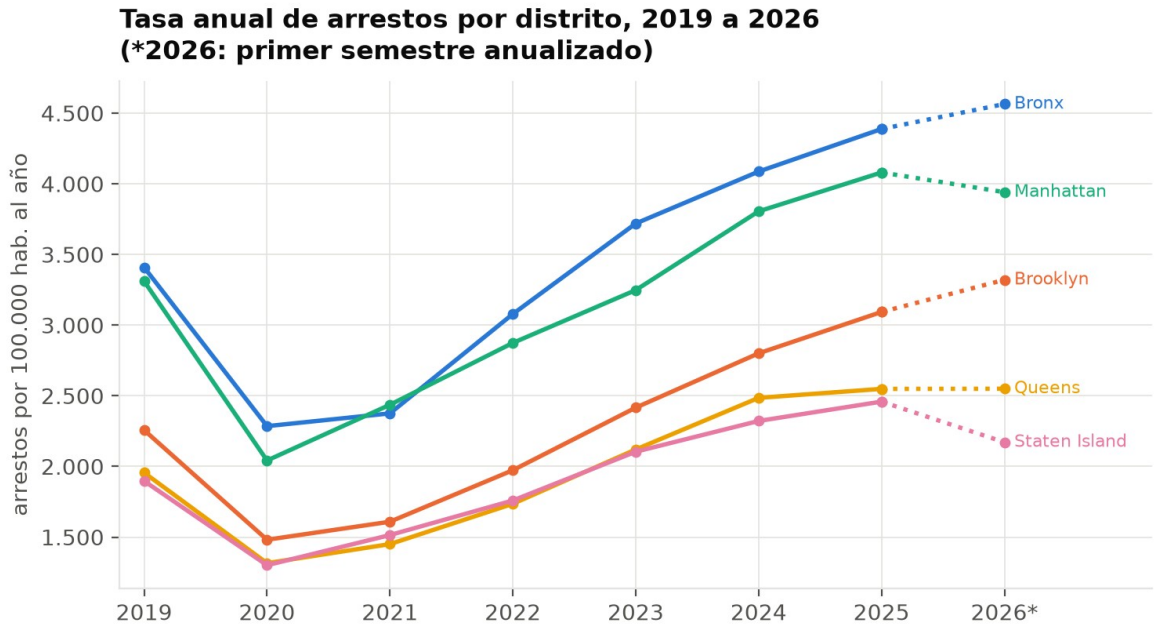
A continuación se responden las ocho preguntas planteadas en el numeral 6, con los resultados del notebook 08_respuestas. Todas las tasas son anuales, se expresan por cada 100.000 habitantes y promedian los años completos de 2019 a 2025. Se emplean tasas y no conteos porque un territorio más poblado registra más arrestos y más choques por el solo hecho de tener más habitantes. Se mantienen las dos precauciones del entendimiento del negocio: los arrestos miden la actividad policial y no la criminalidad, y la población corresponde a los residentes, de modo que las zonas que reciben a diario a muchos trabajadores y visitantes, en particular Manhattan, presentan tasas infladas.

10.1 Tasa de arrestos por distrito y por barrio, y su evolución

La tasa promedio de arrestos va de 3.334 por cada 100.000 habitantes en el Bronx a 1.908 en Staten Island, es decir, 1,7 veces más (figura 12). En todos los distritos la tasa cayó en 2020, el año de la pandemia, y desde entonces ha aumentado de forma sostenida hasta superar el nivel de 2019: entre 2019 y 2025 el aumento fue de 28,7% en el Bronx, 37,0% en Brooklyn, 23,2% en Manhattan, 30,3% en Queens y 29,6% en Staten Island. El dato de 2026 corresponde al primer semestre anualizado, por lo que debe leerse como una proyección.

Figura 12

Tasa anual de arrestos por distrito, de 2019 a 2026.

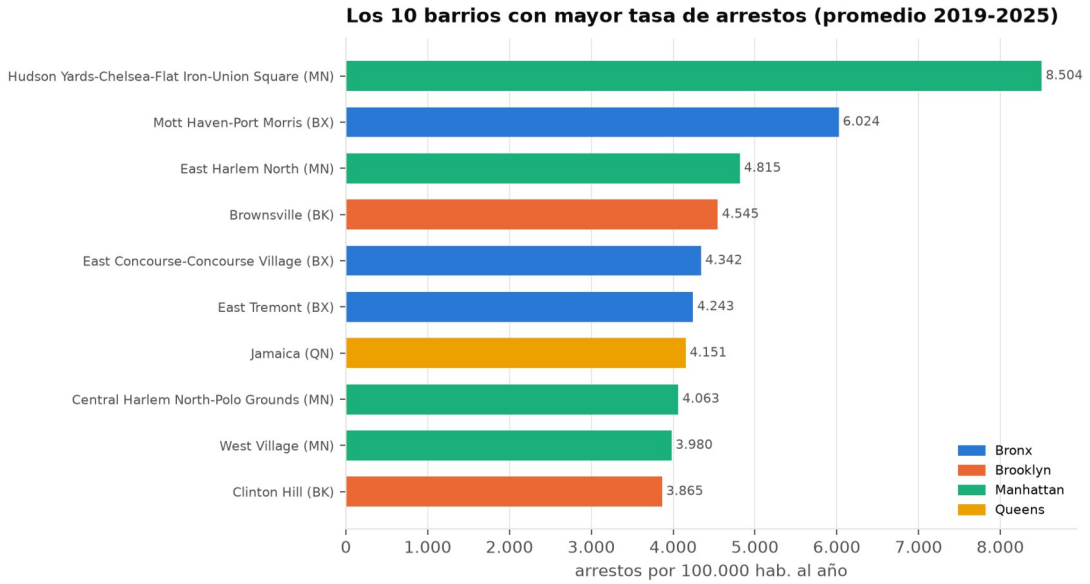


Nota. El valor de 2026 es el primer semestre multiplicado por dos y se representa con línea punteada.

Por barrio, la diferencia es mucho más marcada que por distrito: la tasa va de 686 a 8.504 arrestos por cada 100.000 habitantes, con una mediana de 2.173 (figura 13). Los diez barrios con mayor tasa se reparten entre Manhattan (4), el Bronx (3), Brooklyn (2) y Queens (1). El primer lugar lo ocupa Hudson Yards-Chelsea-Flat Iron-Union Square, en el centro de Manhattan, con una tasa cerca de cuatro veces superior a la mediana; este resultado refleja probablemente la población flotante de la zona, pues los arrestos ocurren allí pero se dividen entre sus residentes. Entre 2019 y 2025 la tasa aumentó en 50 de los 55 barrios.

Figura 13

Los diez barrios con mayor tasa anual de arrestos, promedio 2019–2025.



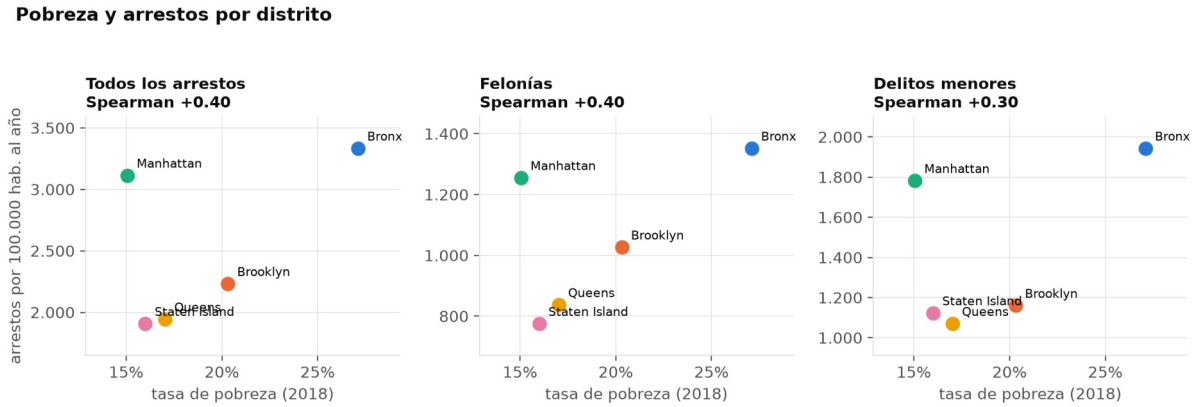
10.2 Pobreza y arrestos por distrito

El distrito más pobre, el Bronx (27,1% de su población en situación de pobreza), es también el de mayor tasa de arrestos. Sin embargo, Manhattan, el menos pobre (15,1%), ocupa el segundo lugar (figura 14). Con los cinco distritos, la correlación de Spearman entre pobreza y tasa de arrestos es de +0,40; al excluir Manhattan, el orden de pobreza de los cuatro distritos restantes coincide exactamente con el de arrestos. La relación se mantiene al separar por gravedad: +0,40 en las felonías y +0,30 en los delitos menores.

En consecuencia, los distritos con mayor pobreza sí presentan más arrestos por habitante, con la excepción de Manhattan, que se explica por su población flotante. Dado que solo hay cinco observaciones, este resultado es descriptivo: no permite afirmar una relación estadística ni, menos aún, que la pobreza cause los arrestos.

Figura 14

Tasa de pobreza y tasa anual de arrestos por distrito, en total y según la gravedad.

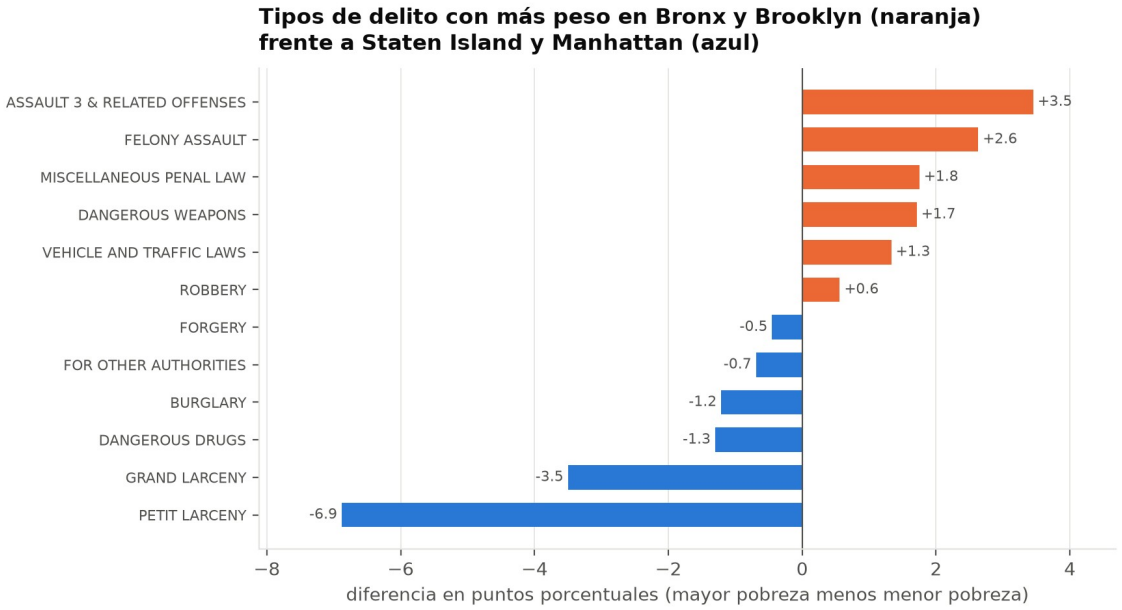


10.3 Tipos de delito según el nivel de pobreza

Se compararon los dos distritos con mayor pobreza (el Bronx y Brooklyn) con los dos de menor pobreza (Manhattan y Staten Island), midiendo qué porcentaje de los arrestos de cada grupo corresponde a cada tipo de delito (figura 15). En los distritos más pobres tienen mayor peso las agresiones y los delitos relacionados con armas: agresión en tercer grado (3,5 puntos porcentuales más), agresión grave (2,6 puntos porcentuales más), otras infracciones al código penal (1,8 puntos porcentuales más) y armas peligrosas (1,7 puntos porcentuales más). En los menos pobres pesan más los hurtos: hurto menor (6,9 puntos porcentuales más) y hurto mayor (3,5 puntos porcentuales más). Una posible explicación, que estos datos no permiten comprobar, es la mayor actividad comercial y turística de Manhattan.

Figura 15

Tipos de delito con mayor diferencia de participación entre los distritos de mayor y de menor pobreza.



Nota. Diferencia en puntos porcentuales entre la participación del delito en los arrestos de cada grupo de distritos.

10.4 Barrios con mayor tasa de choques con heridos o muertos

La tabla 10 presenta los diez barrios con mayor tasa de choques graves y la figura 16 muestra su distribución en la ciudad. El primero es Hudson Yards-Chelsea-Flat Iron-Union Square, con 706 choques graves por cada 100.000 habitantes al año, frente a una mediana de 417 en los 55 barrios. Los diez se concentran en Brooklyn (5), Queens (3), Manhattan (1) y el Bronx (1); reúnen el 17,1% de la población de la ciudad y el 25,5% de los choques graves ubicados en un barrio.

Tabla 10

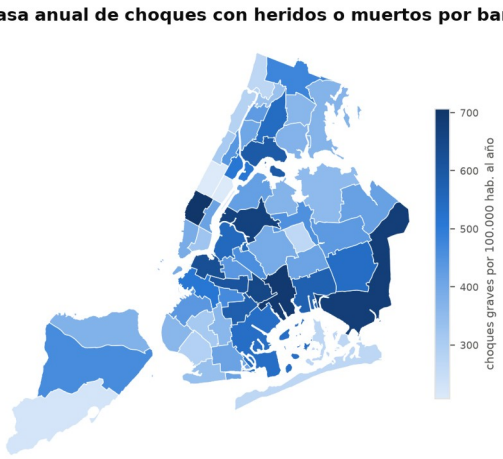
Los diez barrios con mayor tasa anual de choques con heridos o muertos

N.º	Barrio (distrito)	Población 2018	Choques graves por 100.000 hab.	Heridos por 100.000 hab.	% de choques graves
1	Hudson Yards-Chelsea-Flat Iron-Union Square (MN)	148.744	706	811	29,6
2	East New York (BK)	159.382	692	996	34,9
3	Queens Village (QN)	192.800	681	998	35,7
4	Hunters Point-Sunnyside-West Maspeth (QN)	136.810	668	868	35,0
5	Brownsville (BK)	123.329	653	925	35,2
6	Clinton Hill (BK)	121.961	628	784	31,7
7	Crown Heights North (BK)	126.877	607	796	37,6
8	Mott Haven-Port Morris (BX)	161.641	591	808	33,8
9	Rugby-Remsen Village (BK)	139.873	580	829	39,5
10	South Ozone Park (QN)	126.092	572	822	36,4

Nota. Promedio anual de 2019 a 2025. BX: Bronx; BK: Brooklyn; MN: Manhattan; QN: Queens; SI: Staten Island. Cada barrio se identifica con el nombre de su vecindario más poblado.

Figura 16

Tasa anual de choques con heridos o muertos en los 55 barrios, promedio 2019–2025.



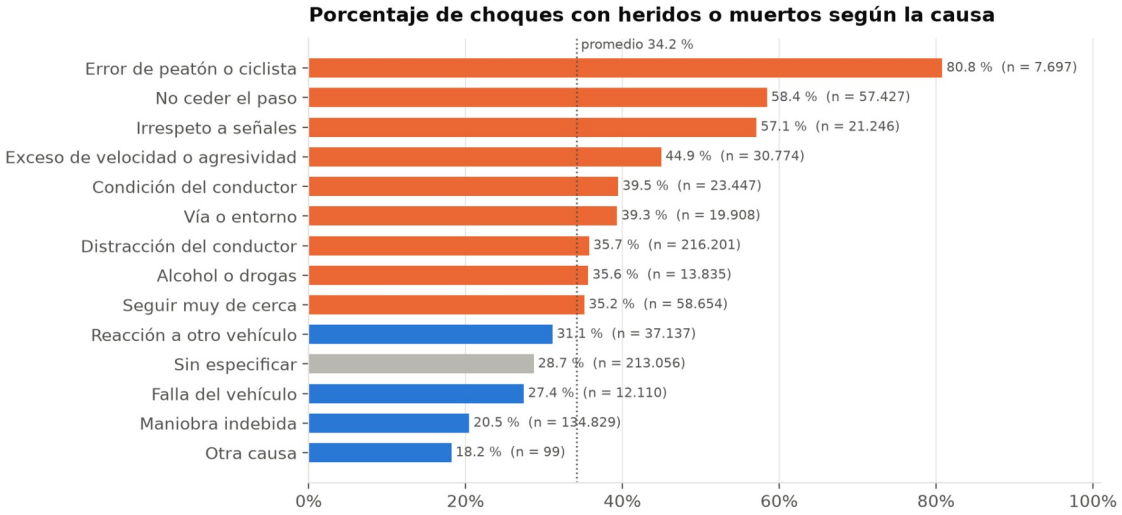
10.5 Causas y tipos de vehículo asociados a la gravedad

En promedio, el 34,2% de los choques registrados deja al menos un herido o un muerto. Las causas con mayor proporción de choques graves son error de peatón o ciclista (80,8%), no ceder el paso (58,4%) e irrespeto a señales (57,1%); las de menor proporción son falla del vehículo (27,4%) y maniobra indebida (20,5%) (figura 17). Las tres primeras tienen en común que involucran el cruce de trayectorias entre usuarios de la vía, situación que suele presentarse

en las intersecciones, aunque los datos no registran si el choque ocurrió en una. El exceso de velocidad no encabeza la lista por proporción de choques graves, pero sí por letalidad: registra 121 muertes por cada 10.000 choques, la cifra más alta entre todas las causas.

Figura 17

Porcentaje de choques con heridos o muertos según la causa.



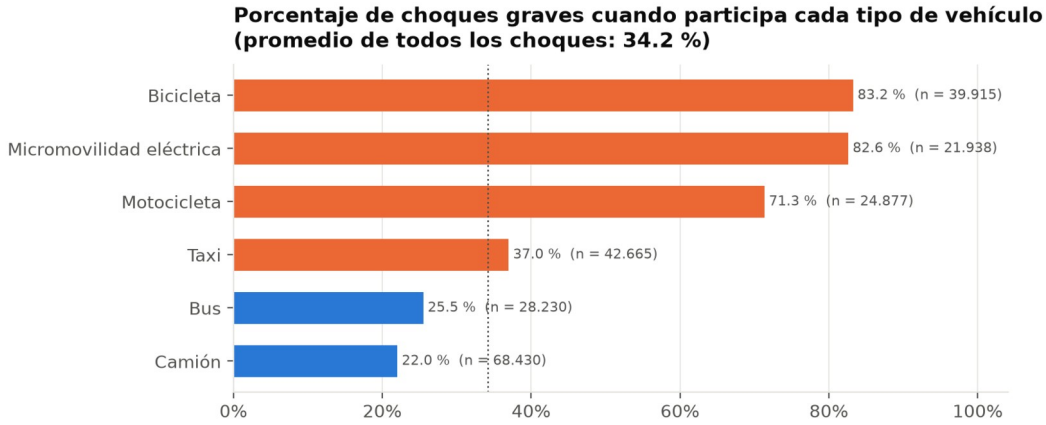
Nota. La línea punteada indica el promedio de todos los choques. En gris, los choques sin causa especificada.

Por tipo de vehículo, la diferencia es aún mayor (figura 18). Cuando participa una bicicleta, el 83,2% de los choques deja víctimas; con vehículos de micromovilidad eléctrica, el 82,6%; y con motocicletas, el 71,3%, es decir, entre 2,1 y 2,4 veces el promedio. En cambio, los choques con buses (25,5%) y camiones (22,0%) dejan víctimas con menor frecuencia que el promedio. En letalidad el orden es otro: se registran 141 muertes por cada 10.000 choques con motocicletas, 83 con vehículos de micromovilidad eléctrica, 41 con camiones y 34 con bicicletas.

Estos porcentajes deben leerse teniendo en cuenta que la fuente solo incluye los choques reportados a la policía, y que un choque leve con una bicicleta se reporta con menor probabilidad que uno con heridos. Ello eleva la proporción de choques graves de los usuarios vulnerables, pero no cambia el sentido del resultado.

Figura 18

Porcentaje de choques con heridos o muertos cuando participa cada tipo de vehículo.



10.6 Horas y días de mayor concentración de choques graves

Los choques graves se concentran en la tarde: el 38,0% ocurre entre las 14:00 y las 19:59, con un máximo a las 17:00 de los días laborales, mientras que entre la medianoche y las 5:59 ocurre el 12,6%. Este patrón es homogéneo entre distritos: la correlación entre los perfiles de 168 franjas (siete días por 24 horas) de cada par de distritos va de 0,89 a 0,98, y la hora de mayor frecuencia es la misma en cuatro de los cinco (figura 19 y tabla 11). La excepción parcial es Staten Island, cuyo máximo se adelanta a las 15:00 y donde la noche tiene menos peso.

Figura 19

Distribución por hora de los choques con heridos o muertos en cada distrito.

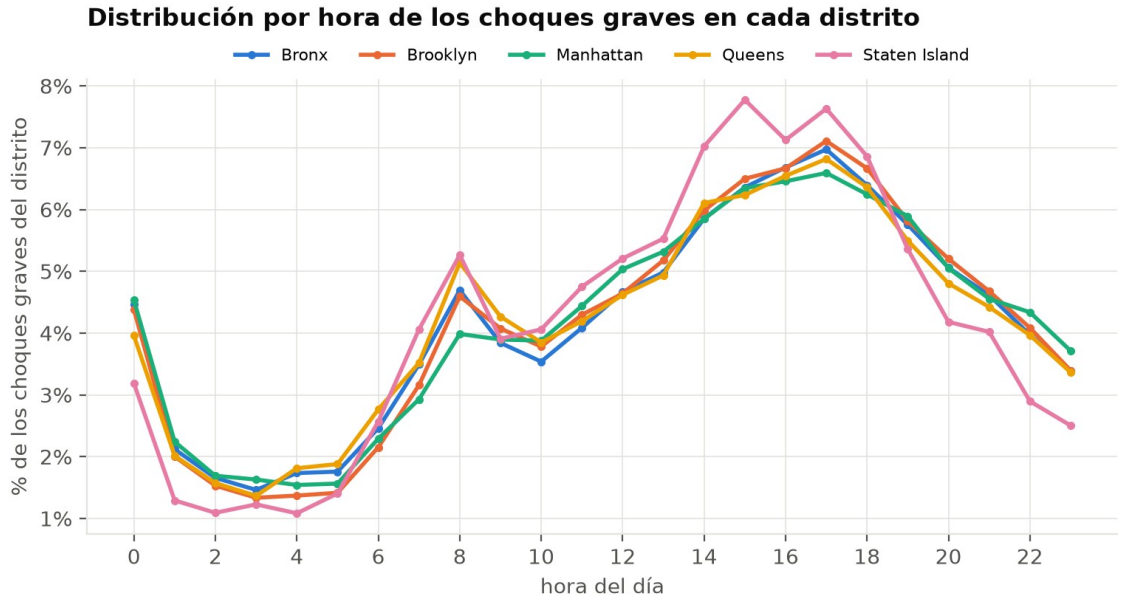


Tabla 11
Concentración horaria de los choques graves por distrito

Distrito	Hora de mayor frecuencia	% de los graves que ocurre de noche	% de los graves en fin de semana	% de choques graves, de noche	% de choques graves, de día
Bronx	17:00	30,2	26,5	36,6	33,7
Brooklyn	17:00	29,4	26,1	38,4	34,5
Manhattan	17:00	30,9	26,6	34,5	30,6
Queens	17:00	29,2	26,9	34,4	33,6
Staten Island	15:00	22,9	24,5	31,1	34,9

Nota. La noche comprende de las 20:00 a las 5:59. Las dos últimas columnas indican qué porcentaje de los choques de cada franja deja heridos o muertos.

Además de cuándo hay más choques graves, interesa cuándo un choque tiene más probabilidad de serlo. En el Bronx, Brooklyn, Manhattan y Queens, un choque nocturno deja víctimas con mayor frecuencia que uno diurno; en Staten Island ocurre lo contrario.

10.7 Barrios prioritarios por arrestos y choques graves

Se consideró que un barrio es alto en un indicador cuando se ubica en la cuarta parte superior de los 55 barrios, es decir, por encima de 3.170 arrestos y de 523 choques graves por cada 100.000 habitantes al año. Siete barrios superan ambos umbrales a la vez y son los prioritarios (tabla 12 y figura 20): tres en Brooklyn, dos en el Bronx, uno en Manhattan y uno en Queens. En conjunto reúnen el 13,2% de la población de la ciudad. En los 55 barrios las dos tasas tienden a moverse juntas, con una correlación de Spearman de +0,43, lo que indica que los dos problemas comparten territorio solo parcialmente y que conviene tratarlos también por separado. El primer barrio de la lista, en el centro de Manhattan, debe leerse con la salvedad ya mencionada: sus tasas por residente están infladas por la población flotante, de modo que su prioridad obedece al volumen de hechos que ocurren allí y no al riesgo de quienes viven en él.

Tabla 12
Barrios en la cuarta parte más alta de arrestos y de choques graves

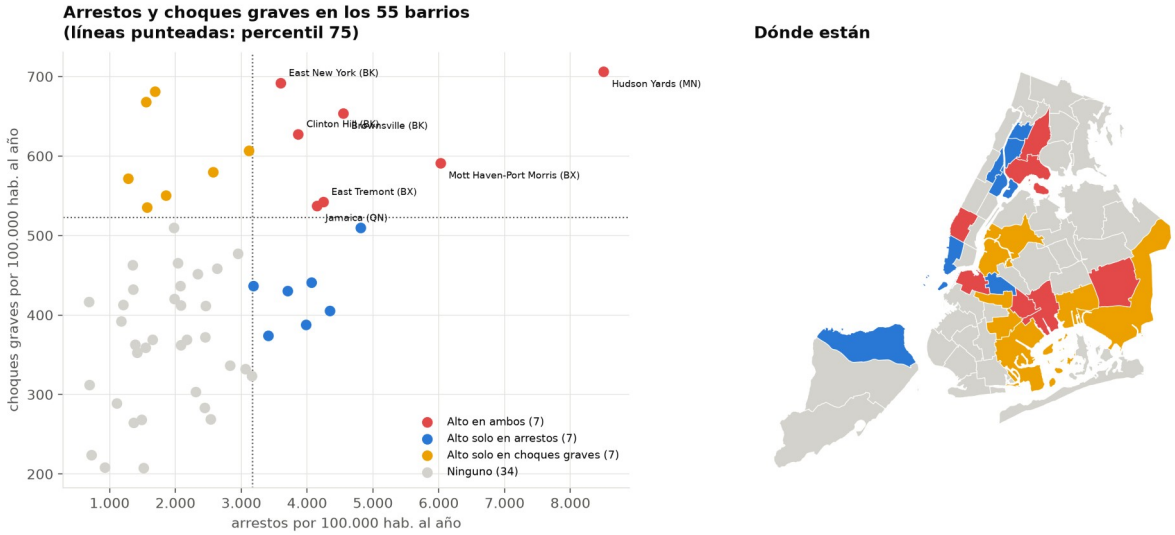
Barrio (distrito)	Población 2018	Arrestos por 100.000 hab.	Posición en arrestos	Choques graves por 100.000 hab.	Posición en choques graves
Hudson Yards-Chelsea-Flat Iron-Union Square (MN)	148.744	8.504	1	706	1
East New York (BK)	159.382	3.596	12	692	2
Brownsville (BK)	123.329	4.545	4	653	5

Barrio (distrito)	Población 2018	Arrestos por 100.000 hab.	Posición en arrestos	Choques graves por 100.000 hab.	Posición en choques graves
Clinton Hill (BK)	121.961	3.865	10	628	6
Mott Haven-Port Morris (BX)	161.641	6.024	2	591	8
East Tremont (BX)	165.682	4.243	6	542	12
Jamaica (QN)	226.348	4.151	7	537	13

Nota. Promedio anual de 2019 a 2025. La posición va de 1 (tasa más alta) a 55.

Figura 20

Arrestos y choques graves en los 55 barrios, y ubicación de los barrios prioritarios.



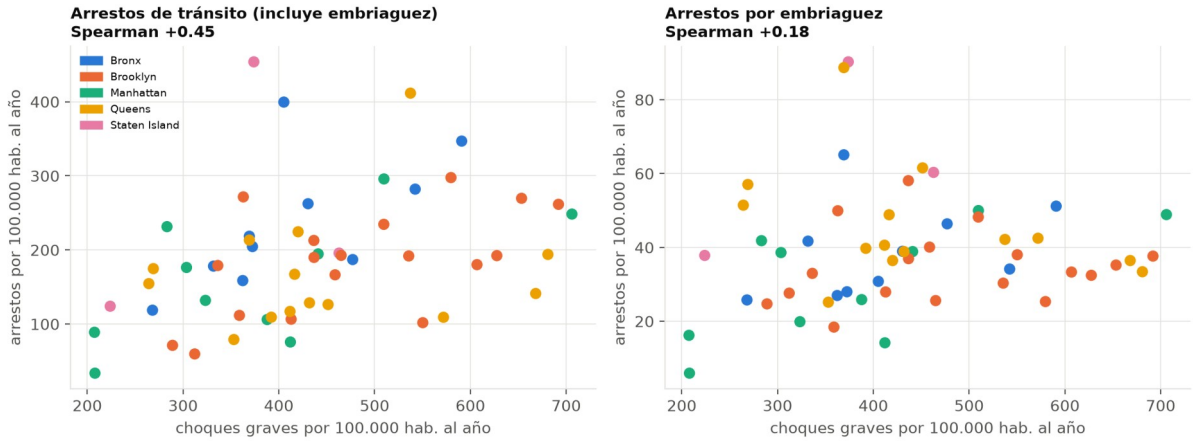
Nota. Las líneas punteadas marcan el percentil 75 de cada indicador.

10.8 Arrestos de tránsito y accidentalidad grave

Si el control de tránsito se concentrara donde está el problema, los barrios con más choques graves tendrían también más arrestos por infracciones de tránsito. La relación existe, pero es moderada: la correlación de Spearman entre ambas tasas es de +0,45, y con los arrestos por conducción en estado de embriaguez es de apenas +0,18 (figura 21). Se identificaron cuatro barrios con una brecha de control, esto es, ubicados en la cuarta parte más alta de choques graves y en la mitad inferior de arrestos de tránsito: Hunters Point-Sunnyside-West Maspeth (QN), Crown Heights North (BK), South Ozone Park (QN) y North Side-South Side (BK).

Figura 21

Tasa de choques graves y tasa de arrestos de tránsito en los 55 barrios.



Este resultado debe interpretarse con cautela. Un menor número de arrestos de tránsito no implica que en un barrio se cometan menos infracciones, sino que allí se realizan menos intervenciones de este tipo; además, las sanciones de tránsito que no terminan en arresto, como los comparendos, no figuran en esta fuente.

11. Selección de técnicas de aprendizaje de máquina

Se seleccionó una técnica supervisada y una no supervisada de la biblioteca MLlib de Apache Spark, cada una asociada a una parte del objetivo de negocio.

Técnica supervisada: Random Forest. El objetivo pide identificar qué circunstancias de un choque elevan el riesgo de que haya heridos. Se planteó como un problema de clasificación binaria: dado un choque, predecir si deja al menos un herido o un muerto. Se eligió un bosque aleatorio por tres razones. Primera, casi todas las variables disponibles son categóricas (causa, distrito, día) y sus efectos no son lineales ni independientes, pues la hora no pesa igual según el día o el tipo de vehículo; un conjunto de árboles de decisión captura esas interacciones sin que haya que definirlas de antemano. Segunda, admite pesos por observación, lo que permite compensar que los choques graves sean la clase minoritaria. Tercera, entrega la importancia de cada variable, que es precisamente la información que requiere el objetivo. Como referencia se entrenó una regresión logística, el modelo más simple para este problema: si el bosque no la superara, su mayor complejidad no estaría justificada.

Técnica no supervisada: K-Means. El objetivo también pide recomendar dónde priorizar las intervenciones. Agrupar los 55 barrios según sus tasas de arrestos y de choques permite proponer un mismo tipo de intervención para cada grupo, en lugar de 55 planes distintos. Se eligió K-Means porque sus grupos se describen mediante el promedio de cada

variable, lo que facilita explicarlos a quienes toman las decisiones, y porque con 55 observaciones y variables numéricas continuas es una técnica adecuada y estable.

Bono: perceptrón multicapa. Como modelo de aprendizaje profundo se entrenó una red neuronal de capas completamente conectadas (MultilayerPerceptronClassifier) sobre el mismo problema supervisado, con el fin de compararla con las dos técnicas anteriores bajo las mismas métricas.

12. Preparación de datos para el modelado

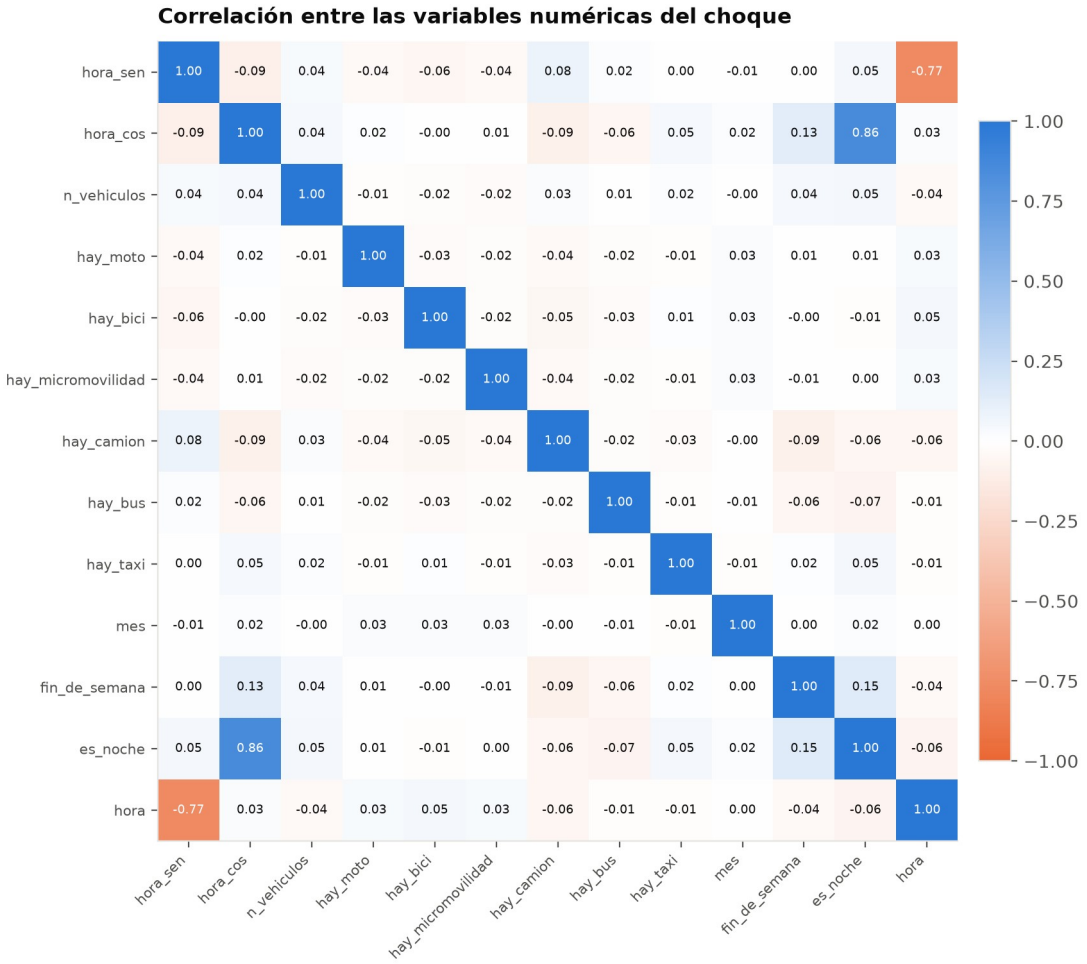
12.1 Modelo supervisado

Los datos de entrada son los 796.667 choques del periodo que tienen distrito y hora registrados, de los cuales el 34,1% es grave. Las variables que describen las víctimas (número de heridos y de muertos, en total y por tipo) se excluyeron porque definen la variable objetivo: incluirlas equivaldría a entregarle la respuesta al modelo.

Eliminación de variables correlacionadas. Se calculó con MLlib la correlación de Pearson entre las variables numéricas candidatas (figura 22). La hora se representó deliberadamente de varias formas: como número, mediante su seno y su coseno, que conservan el carácter circular del tiempo (las 23:00 y las 0:00 son contiguas), y con un indicador de nocturnidad. De cada pareja con correlación igual o superior a 0,8 en valor absoluto se eliminó la variable de menor prioridad según el criterio de negocio. Solo una pareja superó el umbral: el indicador de nocturnidad y el coseno de la hora, por lo que se eliminó el primero.

Figura 22

Correlación entre las variables numéricas candidatas del modelo supervisado.



Selección según el criterio de negocio. Se retiraron además dos variables que la correlación no señala: la hora como número, que trata como extremos opuestos dos horas contiguas, y el indicador de fin de semana, que es una función exacta del día de la semana, ya incluido como categoría. El conjunto final consta de 13 variables (tabla 13), todas referidas a las circunstancias del choque: cuándo, dónde, por qué y con qué vehículos ocurrió.

Tabla 13

Variables finales del modelo supervisado

Variable	Tipo	Descripción
Hora (seno)	Numérica	Hora del choque (componente seno)
Hora (coseno)	Numérica	Hora del choque (componente coseno)
Número de vehículos	Numérica	Número de vehículos involucrados
Presencia de motocicleta	Numérica	1 si participó una motocicleta
Presencia de bicicleta	Numérica	1 si participó una bicicleta

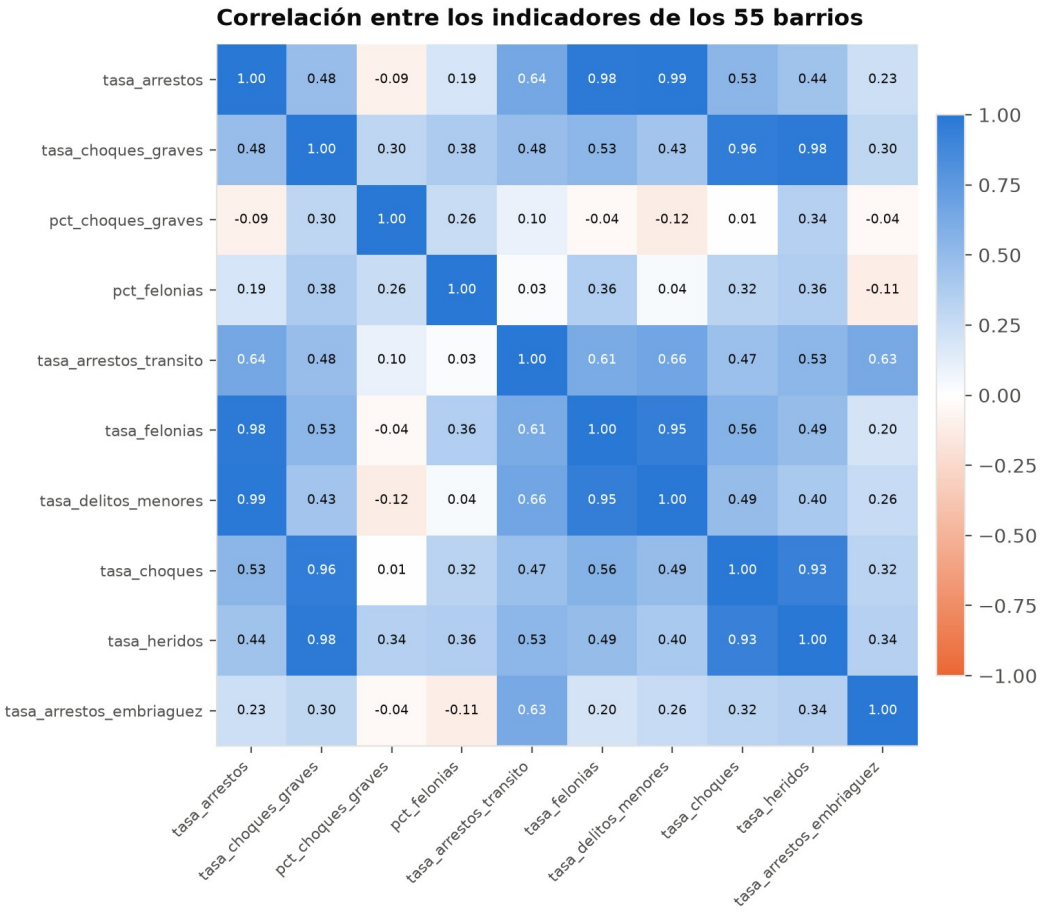
Variable	Tipo	Descripción
Presencia de micromovilidad eléctrica	Numérica	1 si participó una bicicleta o patineta eléctrica
Presencia de camión	Numérica	1 si participó un camión
Presencia de bus	Numérica	1 si participó un bus
Presencia de taxi	Numérica	1 si participó un taxi
Mes	Numérica	Mes del año (1 a 12)
Causa del choque	Categórica	Causa del choque (12 grupos, más «Otra causa» y «Sin especificar»)
Distrito	Categórica	Distrito (5)
Día de la semana	Categórica	Día de la semana (7)

Normalización, codificación y partición. Los datos se dividieron al azar, con semilla fija, en 637.413 choques para entrenamiento (80%) y 159.254 para la prueba final (20%). Las variables numéricas se llevaron a media cero y desviación estándar uno con StandardScaler, ajustado únicamente con los datos de entrenamiento; la regresión logística y la red neuronal lo requieren, mientras que a los árboles no les afecta la escala. Las variables categóricas se convirtieron en índices con StringIndexer y, para los modelos que lo necesitan, en columnas binarias con OneHotEncoder, con lo cual la entrada queda en 39 columnas. Para compensar el desbalance, cada choque recibió un peso inversamente proporcional al tamaño de su clase.

12.2 Modelo no supervisado

La entrada es la tabla de los 55 barrios con sus tasas anuales. Como las tasas están muy concentradas en unos pocos barrios centrales, se aplicó el logaritmo antes de normalizar; de lo contrario, esos barrios dominarían las distancias y quedarían aislados en un grupo propio. La correlación entre las diez variables candidatas (figura 23) mostró cuatro redundancias, todas esperables: las tasas de felonías y de delitos menores con la tasa de arrestos, y las tasas de choques y de heridos con la tasa de choques graves. Tras eliminarlas quedaron seis variables: tasa de arrestos, tasa de choques graves, porcentaje de choques graves, porcentaje de felonías, tasa de arrestos de tránsito y tasa de arrestos por embriaguez, que se normalizaron con StandardScaler para que todas pesen lo mismo en la distancia.

Figura 23
Correlación entre los indicadores candidatos de los 55 barrios.



La pobreza y la educación no se incluyeron como variables porque solo existen por distrito: todos los barrios de un mismo distrito tendrían el mismo valor y el algoritmo terminaría agrupándolos por distrito. Se emplean después, únicamente para describir los grupos.

13. Aplicación y evaluación de los modelos

Los modelos se entrenaron con MLlib en el clúster descrito en el numeral 3.1; el código y sus resultados se encuentran en el notebook 09_modelos.

13.1 Modelos supervisados y prueba de parámetros

Para cada técnica se probaron varias combinaciones de parámetros con TrainValidationSplit sobre una muestra de 191.874 choques del conjunto de entrenamiento, usando el 80% de la muestra para ajustar y el 20% para validar (tabla 14). La combinación con mayor área bajo la curva ROC en validación se volvió a entrenar con todo el conjunto de entrenamiento. En la regresión logística la regularización no aportó: el mejor resultado se obtuvo sin ella. En el Random Forest, aumentar la profundidad de los árboles de 6 a 10 mejoró el resultado de forma apreciable, mientras que pasar de 10 a 14 o duplicar el número de árboles

lo mejoró solo marginalmente. En la red neuronal, la arquitectura con dos capas ocultas superó a la de una sola.

Tabla 14
Combinaciones de parámetros probadas y resultado en validación

Técnica	Parámetros	AUC-ROC en validación
Regresión logística	regularización = 0,0, mezcla L1 = 0,0	0,7209
Regresión logística	regularización = 0,0, mezcla L1 = 0,5	0,7209
Regresión logística	regularización = 0,01, mezcla L1 = 0,0	0,7207
Regresión logística	regularización = 0,01, mezcla L1 = 0,5	0,7202
Regresión logística	regularización = 0,1, mezcla L1 = 0,0	0,7194
Regresión logística	regularización = 0,1, mezcla L1 = 0,5	0,6962
Random Forest	árboles = 40, profundidad = 6	0,7740
Random Forest	árboles = 40, profundidad = 10	0,7831
Random Forest	árboles = 40, profundidad = 14	0,7841
Random Forest	árboles = 80, profundidad = 6	0,7755
Random Forest	árboles = 80, profundidad = 10	0,7833
Random Forest	árboles = 80, profundidad = 14	0,7843
Red neuronal (MLP)	capas = [39, 16, 2], iteraciones = 60	0,7661
Red neuronal (MLP)	capas = [39, 16, 2], iteraciones = 120	0,7626
Red neuronal (MLP)	capas = [39, 32, 16, 2], iteraciones = 60	0,7841
Red neuronal (MLP)	capas = [39, 32, 16, 2], iteraciones = 120	0,7850

Métricas. La exactitud no es una buena medida cuando las clases están desbalanceadas: un modelo que respondiera siempre «sin víctimas» acertaría en dos de cada tres casos sin detectar un solo choque grave. Por ello la métrica principal es el área bajo la curva ROC (AUC-ROC), que equivale a la probabilidad de que el modelo asigne más riesgo a un choque grave que a uno sin víctimas y no depende del umbral de decisión; 0,5 corresponde al azar y 1 a la clasificación perfecta. Se complementa con el área bajo la curva de precisión y sensibilidad (AUC-PR), centrada en la clase de interés, y con la precisión, la sensibilidad y la medida F1 de la clase «grave».

Resultados. La tabla 15 y la figura 24 presentan la evaluación sobre los 159.254 choques de prueba, que ningún modelo utilizó durante el entrenamiento. El Random Forest alcanza un AUC-ROC de 0,786 y supera con claridad a la regresión logística (0,721), lo que confirma que las interacciones entre variables aportan información. Detecta el 59,3% de los

choques graves con una precisión del 66,9%, y su AUC-PR de 0,703 duplica la referencia de 0,342.

Tabla 15

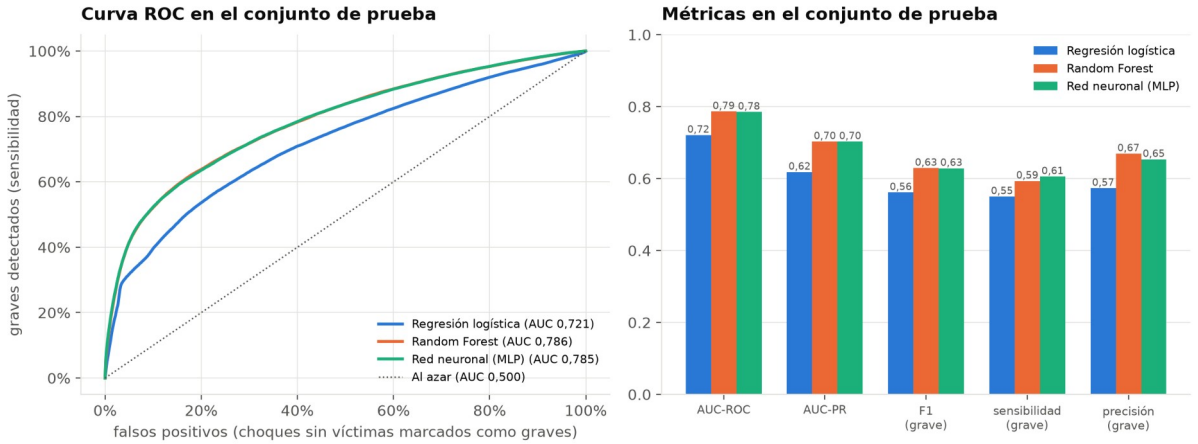
Evaluación de los modelos supervisados en el conjunto de prueba

Modelo	AUC-ROC	AUC-PR	Precisión (grave)	Sensibilidad (grave)	F1 (grave)	Exactitud
Regresión logística	0,721	0,618	0,573	0,550	0,561	0,706
Random Forest	0,786	0,703	0,669	0,593	0,629	0,761
Red neuronal (MLP)	0,785	0,703	0,653	0,606	0,628	0,755
Referencia: predecir siempre «sin víctimas»	0,500	0,342	0,000	0,000	0,000	0,658

Nota. Precisión: de los choques que el modelo marca como graves, proporción que lo es. Sensibilidad: de los choques graves, proporción que el modelo detecta.

Figura 24

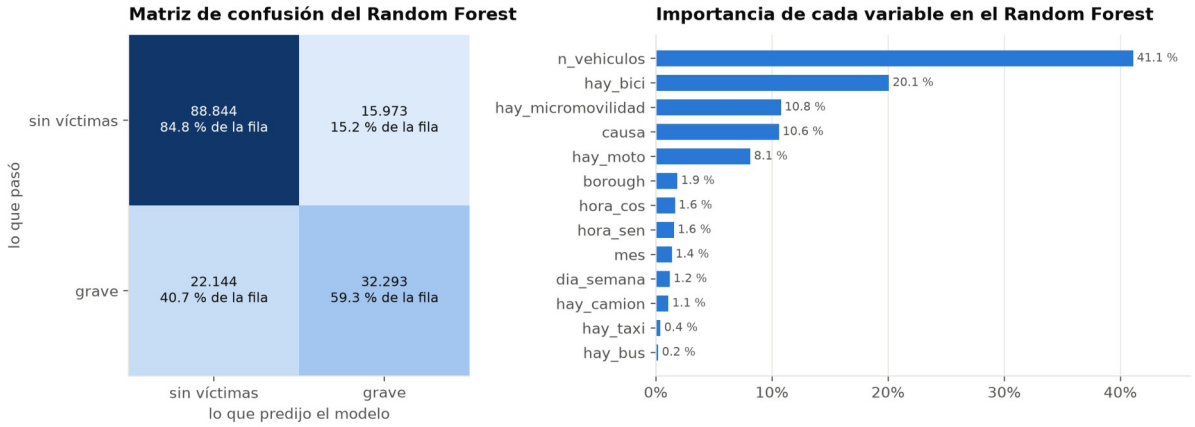
Curva ROC y métricas de los tres modelos en el conjunto de prueba.



La matriz de confusión del Random Forest (figura 25) muestra que, de los 54.437 choques graves de la prueba, el modelo identifica 32.293 y deja pasar 22.144; y que de los 104.817 choques sin víctimas, clasifica erróneamente como graves 15.973. Las variables más importantes son número de vehículos (41,1%), presencia de bicicleta (20,1%), presencia de micromovilidad eléctrica (10,8%), causa del choque (10,6%) y presencia de motocicleta (8,1%), que en conjunto suman el 90,7% de la importancia. Una posible explicación del peso del número de vehículos es que entre los choques con un solo vehículo se cuentan los atropellos, mientras que muchos choques entre varios automóviles dejan solo daños materiales; los datos no permiten separar ambos casos. El distrito, el día y el mes aportan muy poco: lo determinante es quién participa en el choque y por qué ocurre, no dónde ni cuándo.

Figura 25

Matriz de confusión e importancia de las variables del Random Forest.



El desempeño debe valorarse considerando que el modelo desconoce factores que inciden directamente en la gravedad, como la velocidad real del impacto, la presencia de peatones, el uso del cinturón o el estado de la vía. Con las circunstancias disponibles, su capacidad de discriminación es aceptable y suficiente para el propósito planteado, que es ordenar las circunstancias según el riesgo asociado. No es un modelo para anticipar choques antes de que ocurran, pues la causa y los vehículos solo se conocen después del hecho. La importancia indica cuánto utiliza el modelo cada variable, pero no el sentido de su efecto; este se encuentra en el numeral 10.5.

13.2 Bono: red neuronal

El perceptrón multicapa recibió las mismas 39 columnas normalizadas y codificadas que la regresión logística. Como esta clase de MLlib no admite pesos por observación, el desbalance se compensó entrenando con una muestra balanceada, formada por todos los choques graves y una muestra aleatoria de igual tamaño de los demás; la evaluación se realizó sobre el conjunto de prueba original, sin balancear. La mejor arquitectura, con dos capas ocultas de 32 y 16 neuronas, obtuvo un AUC-ROC de 0,785 y detectó el 60,5% de los choques graves con una precisión del 65,3%. Su desempeño es prácticamente igual al del Random Forest. Se concluye que, con estas variables, el límite lo impone la información disponible y no la técnica; entre ambos se prefiere el Random Forest por ser más fácil de interpretar.

13.3 Modelo no supervisado

Se entrenó K-Means con entre 2 y 8 grupos y tres semillas distintas para cada valor, dado que el algoritmo parte de centros aleatorios (tabla 16 y figura 26). Se emplearon dos métricas: la silueta, que va de −1 a 1 y compara la cercanía de cada barrio a su grupo frente al grupo vecino, y la inercia, que suma las distancias al cuadrado de cada barrio al centro de su

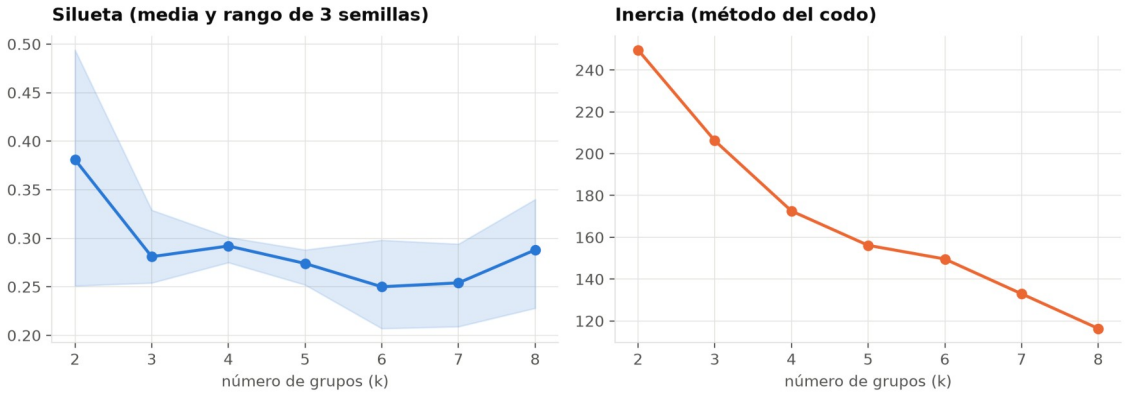
grupo y sirve para identificar el punto a partir del cual añadir grupos deja de aportar (método del codo).

Tabla 16
Resultados de K-Means según el número de grupos

Grupos (k)	Silueta media	Rango de la silueta	Inercia media	Barrios en el grupo más pequeño
2	0,381	0,251 a 0,494	249,6	9
3	0,281	0,254 a 0,329	206,2	7
4	0,292	0,275 a 0,301	172,6	5
5	0,274	0,252 a 0,288	156,1	1
6	0,250	0,207 a 0,298	149,6	1
7	0,254	0,209 a 0,294	133,0	1
8	0,288	0,228 a 0,340	116,4	1

La mayor silueta corresponde a dos grupos (0,381), pero una división en «alto» y «bajo» no permite diferenciar intervenciones. Entre 3 y 6 grupos, la mejor silueta media es la de k = 4; además, a partir de k = 5 aparece un grupo formado por un solo barrio. Se seleccionó por tanto k = 4, con una silueta de 0,30. Este valor indica una separación moderada, lo cual es esperable: los barrios forman un continuo y no conjuntos nítidamente separados, de modo que los barrios cercanos al límite entre dos grupos podrían cambiar de grupo con otra semilla.

Figura 26
Silueta e inercia de K-Means según el número de grupos.



La tabla 17 presenta el perfil de cada grupo en las unidades originales y la figura 27 su ubicación. Los grupos se numeraron de mayor a menor tasa de arrestos.

Tabla 17
Perfil de los grupos de barrios obtenidos con K-Means

Grupo	Barrios	Población	Arrestos por 100.000 hab.	Choques graves por 100.000 hab.	% de choques graves	% de felonías	Arrestos de tránsito por 100.000 hab.
Grupo 1	13	1.953.279	4.478	537	33,8	42,4	293
Grupo 2	19	2.740.240	2.126	379	32,4	41,0	187
Grupo 3	18	2.818.103	1.936	471	36,2	45,6	143
Grupo 4	5	887.130	1.150	239	31,5	36,7	87

Nota. Promedio de los barrios de cada grupo; tasas anuales de 2019 a 2025.

Grupo 1 (13 barrios, 1.953.279 habitantes): 4.478 arrestos por cada 100.000 habitantes (1,8 veces el promedio de los barrios) y 537 choques graves (1,2 veces); el 33,8% de sus choques deja víctimas. Incluye, entre otros, Hudson Yards-Chelsea-Flat Iron-Union Square, Mott Haven-Port Morris, East Harlem North y Brownsville.

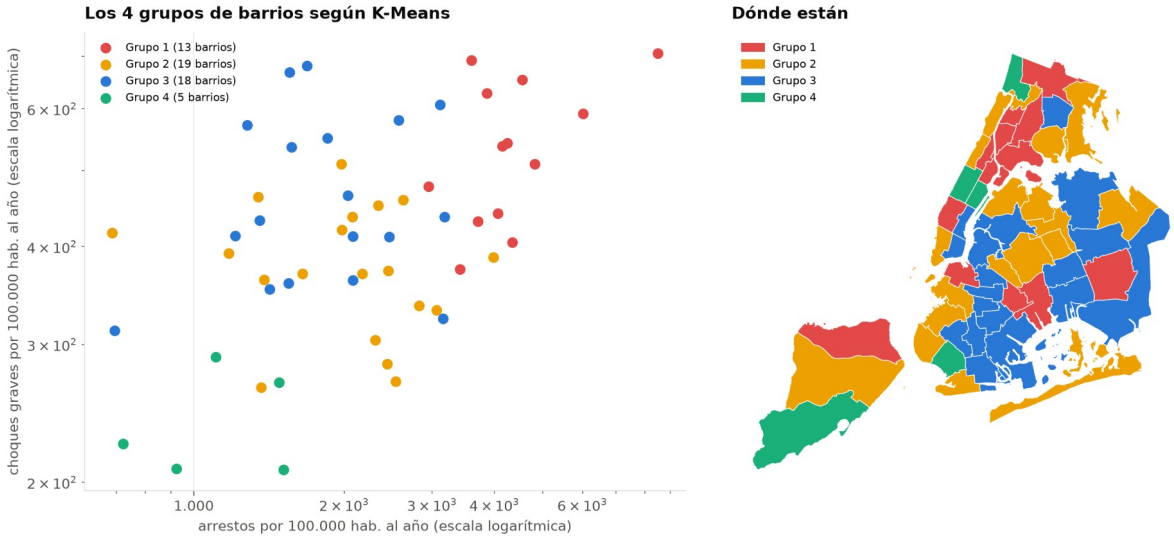
Grupo 2 (19 barrios, 2.740.240 habitantes): 2.126 arrestos por cada 100.000 habitantes (0,8 veces el promedio de los barrios) y 379 choques graves (0,9 veces); el 32,4% de sus choques deja víctimas. Incluye, entre otros, West Village, Bedford Park-Fordham North, Brighton Beach y Bushwick South.

Grupo 3 (18 barrios, 2.818.103 habitantes): 1.936 arrestos por cada 100.000 habitantes (0,8 veces el promedio de los barrios) y 471 choques graves (1,1 veces); el 36,2% de sus choques deja víctimas. Incluye, entre otros, Bedford, Lower East Side, Crown Heights North y Rugby-Remsen Village.

Grupo 4 (5 barrios, 887.130 habitantes): 1.150 arrestos por cada 100.000 habitantes (0,5 veces el promedio de los barrios) y 239 choques graves (0,6 veces); el 31,5% de sus choques deja víctimas. Incluye, entre otros, Upper West Side, Van Cortlandt Village, Bensonhurst West y Lenox Hill-Roosevelt Island.

Figura 27

Grupos de barrios según K-Means y su ubicación en la ciudad.



14. Conclusiones y recomendaciones

14.1 Conclusiones

Los arrestos han aumentado en toda la ciudad desde 2020 y en 2025 superan el nivel previo a la pandemia en los cinco distritos. Las diferencias entre barrios son mucho mayores que entre distritos, por lo que el barrio es la unidad adecuada para focalizar. Los distritos más pobres registran más arrestos por habitante y un mayor peso de los delitos contra las personas, mientras que en los menos pobres predominan los delitos contra la propiedad; Manhattan es una excepción explicada por su población flotante.

En seguridad vial, uno de cada tres choques reportados deja víctimas, y la gravedad depende sobre todo de quién participa: los choques con bicicletas, vehículos de micromovilidad eléctrica y motocicletas dejan heridos o muertos con una frecuencia que supera el doble del promedio. Las causas más asociadas a la gravedad son los errores de peatones y ciclistas, no ceder el paso y el irrespeto a las señales; el exceso de velocidad es la causa más letal. Los choques graves se concentran entre las 14:00 y las 20:00, con el máximo en los días laborales y un patrón casi idéntico en los cinco distritos.

Los modelos confirman estos hallazgos. El Random Forest distingue los choques graves con un AUC-ROC de 0,786 y atribuye la mayor parte de su capacidad al número y tipo de vehículos y a la causa, no al lugar ni al momento. La red neuronal no lo supera, lo que indica que el límite está en la información disponible. K-Means organiza los 55 barrios en cuatro perfiles con necesidades distintas.

El análisis tiene limitaciones que condicionan el alcance de las conclusiones: los arrestos reflejan dónde actúa la policía; las tasas se calculan sobre residentes; la población por barrio es la de 2010 ajustada a 2018; la pobreza y la educación solo están disponibles por distrito y para 2018; y una cuarta parte de los choques no registra la causa. Las relaciones descritas son asociaciones y no permiten afirmar causalidad.

14.2 Recomendaciones

Dónde. Concentrar las intervenciones integrales, sociales y de seguridad vial, en los siete barrios que son altos en ambos indicadores: Hudson Yards-Chelsea-Flat Iron-Union Square (MN), East New York (BK), Brownsville (BK), Clinton Hill (BK), Mott Haven-Port Morris (BX), East Tremont (BX) y Jamaica (QN). En el primero, la intervención debe dirigirse a quienes transitan por la zona más que a sus residentes. En los cuatro barrios con muchos choques graves y poco control de tránsito (Hunters Point-Sunnyside-West Maspeth (QN), Crown Heights North (BK), South Ozone Park (QN) y North Side-South Side (BK)) se recomienda reforzar el control vial. Para el resto de la ciudad, diferenciar la estrategia según el grupo de K-Means: atención integral en el grupo 1; prioridad a la seguridad vial en el grupo 3, que tiene la mayor proporción de choques con víctimas; y seguimiento en el grupo 4, que presenta los valores más bajos.

Cuándo. Programar el control de tránsito y la presencia en vía entre las 14:00 y las 20:00 de lunes a viernes: esas 30 horas de las 168 de la semana concentran el 28,8% de los choques graves, y el patrón es común a todos los distritos, lo que permite una programación única para la ciudad.

Sobre qué. Orientar la inversión en seguridad vial a la protección de ciclistas, usuarios de micromovilidad eléctrica y motociclistas, y al control de las conductas más asociadas a la gravedad: no ceder el paso e irrespetar las señales. El control de velocidad debe mantenerse como prioridad por su letalidad. En los distritos de mayor pobreza, donde predominan los arrestos por agresiones, se recomienda complementar la acción policial con programas de prevención de la violencia.

Con qué información. Mejorar el registro de la causa del choque, hoy ausente en uno de cada cuatro casos, y disponer de estimaciones actualizadas de población por barrio, incluida la población flotante, permitiría afinar estas prioridades. Asimismo, incorporar los comparendos de tránsito, que no figuran en los datos de arrestos, daría una medida más completa del control vial.

Anexo

El código, los notebooks ejecutados de ambas entregas (del 00 al 09) y la documentación técnica de la infraestructura se encuentran disponibles en el repositorio del proyecto: https://github.com/MateoJara/proyecto-nyc-bigdata.

Referencias

New York City Department of City Planning. (2025). New York City's population estimates and trends, May 2025 release (Census Bureau vintage 2024). https://www.nyc.gov/assets/planning/downloads/pdf/our-work/reports/new-york-city-population-estimates-and-trends_may-2025.pdf

New York City Department of Transportation. (2026). Traffic deaths reach all-time low: New York ends year with fewest fatalities ever recorded. https://www.nyc.gov/html/dot/html/pr2026/traffic-deaths-reach-all-time-low.shtml

New York City Mayor's Office for Economic Opportunity. (s. f.). NYCgov poverty measure data dictionary [Documento anexo al conjunto de datos]. NYC Open Data.

New York City Open Data. (s. f.-a). Motor vehicle collisions – Crashes [Conjunto de datos]. https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Crashes/h9gi-nx95/about_data

New York City Open Data. (s. f.-b). Motor vehicle collisions – Vehicles [Conjunto de datos]. https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Vehicles/bm4k-52h4/about_data

New York City Open Data. (s. f.-c). NYPD arrests data (historic) [Conjunto de datos]. https://data.cityofnewyork.us/Public-Safety/NYPD-Arrests-Data-Historic-/8h9b-rp9u/about_data

New York City Open Data. (s. f.-d). NYPD arrest data (year to date) [Conjunto de datos]. https://data.cityofnewyork.us/Public-Safety/NYPD-Arrest-Data-Year-to-Date-/uip8-fykc/about_data

New York City Open Data. (s. f.-e). 2010 Public use microdata areas (PUMAs) [Conjunto de datos]. https://data.cityofnewyork.us/City-Government/2010-Public-Use-Microdata-Areas-PUMAs-/k2r4-n9ax/about_data

New York City Open Data. (s. f.-f). 2012 SAT results [Conjunto de datos]. https://data.cityofnewyork.us/Education/2012-SAT-Results/f9bf-2cp4/about_data

New York City Open Data. (s. f.-g). *New York City population by neighborhood tabulation areas* [Conjunto de datos]. https://data.cityofnewyork.us/City-Government/New-York-City-Population-By-Neighborhood-Tabulatio/swpk-hqdp/about_data

New York City Open Data. (s. f.-h). *2010 census tract to neighborhood tabulation area equivalency table* [Conjunto de datos]. https://data.cityofnewyork.us/City-Government/2010-Census-Tract-to-Neighborhood-Tabulation-Area-/8ius-dhrr/about_data

New York State Department of Health. (2020). Table 2: Population, land area, and population density by county, New York State - 2018. En Vital statistics of New York State 2018. https://www.health.ny.gov/statistics/vital_statistics/2018/table02.htm

New York State Department of Labor. (s. f.). Developments in the New York City labor market. https://dol.ny.gov/labor-statistics-new-york-city-region

Robin Hood, & Columbia University. (2024). The state of poverty and disadvantage in New York City (Poverty Tracker, Annual Report 2024). https://robinhood.org/wp-content/uploads/2024/02/Annual-Poverty-Tracker-Report-2024.pdf

The Apache Software Foundation. (s. f.-a). Apache Spark 4.1.3 documentation. https://spark.apache.org

The Apache Software Foundation. (s. f.-b). Apache Hadoop 3.5.0 documentation. https://hadoop.apache.org

U.S. Bureau of Economic Analysis. (s. f.). Total gross domestic product for New York-Newark-Jersey City, NY-NJ-PA (MSA) [Serie de datos NGMP35620]. FRED, Federal Reserve Bank of St. Louis. https://fred.stlouisfed.org/series/NGMP35620

U.S. Bureau of Labor Statistics. (2025). Alternative measures of labor underutilization in New York — 2025. https://www.bls.gov/regions/northeast/news-release/laborunderutilization_newyork.htm