

**PROYECTO: ANALÍTICA DE BIG DATA PARA LA SEGURIDAD Y MOVILIDAD
EN NUEVA YORK**

PROCESAMIENTO DE DATOS A GRAN ESCALA



AUTORES

Martín Sarmiento Galeano

Mateo Jaramillo Londoño

Wilson Muñoz Torres

Presentado a: Felipe Cuervo Perez

Fecha de entrega: 30/09/2026

1. Entendimiento del negocio

Nueva York es la ciudad más poblada de Estados Unidos, con 8,48 millones de habitantes según las estimaciones más recientes de la Oficina del Censo (New York City Department of City Planning, 2025), y el centro de la mayor economía metropolitana del país, con un producto interno bruto de 2,3 billones de dólares en 2023 (U.S. Bureau of Economic Analysis, s. f.). Esa magnitud económica convive, sin embargo, con desigualdades marcadas: la tasa ampliada de subutilización laboral (U-6) llegó al 9,4% en 2025 (U.S. Bureau of Labor Statistics, 2025), y la pobreza, medida por Robin Hood y la Universidad de Columbia, pasó del 18% en 2021 al 23% en 2022 (Robin Hood & Columbia University, 2024). Con los datos oficiales de pobreza de la ciudad correspondientes a 2018, la tasa por distrito (borough) va del 15,1% en Manhattan al 27,1% en el Bronx.

En seguridad vial, la ciudad implementa desde 2014 la estrategia Vision Zero, orientada a eliminar las muertes en las vías; en 2025 se registraron 205 muertes, la cifra más baja desde que existe registro (New York City Department of Transportation, 2026), aunque uno de cada tres choques reportados continúa dejando al menos una persona herida o fallecida. En seguridad ciudadana, los arrestos del Departamento de Policía de Nueva York (NYPD) crecieron de forma sostenida desde 2021 y alcanzaron su máximo en 2025, con 278.953 casos.

Cabe aclarar que los arrestos son un indicador de la actividad policial y no una medida directa de la criminalidad; un incremento puede reflejar más delitos, pero también una mayor presencia u operativos de la policía. Por esta razón, en el proyecto los arrestos se interpretan como un indicador de intervención del Estado y se analizan junto con variables de contexto social (pobreza y nivel educativo), sin establecer relaciones de causalidad entre ellas.

Con este panorama, el objetivo de negocio de la consultoría es identificar en qué zonas de la ciudad se concentran los arrestos y los accidentes viales graves en relación con su población, cómo esa concentración se asocia con la pobreza y el nivel educativo de cada distrito, y qué circunstancias de cada choque (causas, vehículos involucrados y franja horaria) elevan el riesgo de que existan heridos, para recomendar al gobierno dónde y cuándo priorizar sus intervenciones sociales, de seguridad vial y de control.

2. Selección de los datos a utilizar

Todas las fuentes principales son públicas y provienen de NYC Open Data, el portal de datos abiertos de la alcaldía de Nueva York, que identifica cada conjunto con un código de ocho caracteres. La selección responde directamente al objetivo de negocio: dos fuentes miden los fenómenos de interés (arrestos y choques), una aporta el detalle de los vehículos involucrados en los choques, y dos permiten caracterizar el contexto social y educativo de cada distrito (pobreza y resultados del SAT); una séptima fuente, los límites de los barrios estadísticos (PUMA), permite ubicar espacialmente los eventos.

Tabla 1*Fuentes de datos seleccionadas*

Fuente (identificador)	Contenido	Justificación
Arrestos históricos del NYPD (8h9b-rp9u)	Un registro por arresto desde 2006, con fecha, tipo y gravedad del delito, distrito, coordenadas, edad, sexo y raza.	Primer indicador del caso de negocio.
Arrestos del año en curso (uip8-fykc)	Arrestos de enero a junio de 2026, con las mismas columnas.	Completa el periodo de análisis hasta 2026.
Choques de tránsito (h9gi-nx95)	Un registro por choque: fecha, hora, distrito, coordenadas, heridos y muertos por tipo de víctima, causas y vehículos.	Segundo indicador del caso; permite medir la gravedad.
Vehículos en choques (bm4k-52h4)	Un registro por vehículo involucrado: tipo, año, maniobra y datos del conductor.	Detalle adicional para el modelo de gravedad.
NYCgov Poverty Measure, 2018 (cts7-vksw)	Microdatos de la encuesta ACS ampliada por la alcaldía: pobreza, ingreso, educación y distrito, con el peso de cada persona.	Única fuente oficial de pobreza y educación por persona.
Resultados del SAT, 2012 (f9bf-2cp4)	Puntaje promedio por colegio en el examen de admisión universitaria.	Indicador del contexto educativo.
Límites de las PUMA, 2010 (k2r4-n9ax)	Contorno geográfico de los 55 barrios estadísticos de la ciudad.	Permite ubicar cada arresto y cada choque en su barrio.

Nota. Todas las fuentes provienen de NYC Open Data (data.cityofnewyork.us).

El periodo de análisis abarca de 2019 a 2025, más el primer semestre de 2026, para observar el comportamiento previo a la pandemia y disponer del dato más reciente. Se emplean dos niveles geográficos: el distrito (cinco boroughs), en el que se cruzan todas las fuentes, y el barrio o PUMA (55 zonas), en el que se ubican los arrestos y los choques mediante un cruce espacial de sus coordenadas.

Dos fuentes inicialmente contempladas se descartaron: la población por barrio, disponible solo mediante extracción automatizada de una página que bloquea este tipo de acceso, y el clima diario, que se habría obtenido de una interfaz de programación externa. En cambio, la población oficial de cada distrito sí se obtuvo mediante web scraping de otra página del Departamento de Salud del estado, como se describe en la sección 8.

3. Colección y descripción de los datos

3.1 Infraestructura de procesamiento

El volumen del proyecto (cerca de 13 millones de registros y 2,5 gigabytes) excede la capacidad de un único computador, por lo que los datos se procesaron en un clúster distribuido: tres máquinas virtuales de la universidad, cada una con sistema operativo Rocky Linux 9, cuatro núcleos de procesador y 15,7 GB de memoria RAM. Sobre ellas se instalaron Apache Spark 4.1.3, en modo standalone, como motor de procesamiento, y Apache Hadoop 3.5.0 (HDFS) como sistema de almacenamiento distribuido, con replicación de dos copias por bloque (The Apache Software Foundation, s. f.-a, s. f.-b).

Tabla 2

Distribución de funciones en el clúster

Máquina	Funciones asignadas	Recursos para el cálculo
VM1	Master, worker, driver, NameNode y DataNode de HDFS	2 núcleos, 5 GB
VM2	Worker, DataNode	3 núcleos, 8 GB
VM3	Worker, DataNode	3 núcleos, 8 GB
Total	8 executors de 1 núcleo y 2,5 GB cada uno	8 núcleos, 21 GB

La verificación del clúster confirmó su correcto funcionamiento: los ocho executors se conectaron sin inconvenientes, un trabajo de prueba dividido en 200 tareas se distribuyó de forma proporcional a los recursos de cada máquina, y la escritura y lectura de diez millones de filas en HDFS tomó 10,1 y 6,2 segundos, respectivamente. El diseño completo de la infraestructura, junto con el registro de incidencias durante su instalación, se documenta en el repositorio del proyecto.

Las siete fuentes se descargaron íntegramente desde la API de NYC Open Data mediante un script reproducible que registra, para cada archivo, su tamaño, número de líneas y huella criptográfica SHA-256 antes de cargarlo a HDFS. Los archivos, originalmente en formato CSV, se convirtieron a Parquet (formato columnar y comprimido) con una reducción de tamaño de entre 2,6 y 5,2 veces, y se organizaron en capas sucesivas de refinamiento (cruda, bronce, plata y oro), de modo que los datos originales nunca se modifican y el proceso puede rehacerse en cualquier momento. La conversión completa de los 2,5 GB tomó 3,7 minutos.

3.2 Descripción de las fuentes

El significado de cada atributo se obtuvo de los metadatos oficiales publicados por cada entidad en NYC Open Data y, para la encuesta de pobreza, de su diccionario técnico (New York City Mayor's Office for Economic Opportunity, s. f.). La tabla 3 resume el tipo de dato predominante y algunos atributos representativos de cada fuente.

Tabla 3

Tipo y contenido de las principales fuentes

Fuente	Registros	Tipo de datos	Atributos representativos
Arrestos (histórico y año en curso)	6.406.848	Catagóricos y de fecha	Fecha, tipo y gravedad del delito, distrito, edad, sexo, raza, coordenadas
Choques de tránsito	2.269.187	Catagóricos, numéricos y de fecha	Fecha, hora, distrito, heridos/muertos por tipo de víctima, causas, vehículos
Vehículos en choques	4.551.002	Catagóricos	Tipo y año del vehículo, maniobra, punto de impacto, causas
Pobreza (NYCgov)	68.273	Numéricos y catagóricos	Distrito, condición de pobreza, ingreso, nivel educativo, peso muestral
SAT (2012)	478	Numéricos	Puntaje promedio en lectura, matemáticas y escritura por colegio
PUMA (2010)	55	Geoespacial	Código, área y contorno de cada barrio estadístico

La tabla de arrestos identifica cada registro mediante la llave ARREST_KEY y clasifica el delito según su gravedad legal (felonía, delito menor o infracción). La tabla de choques, identificada por COLLISION_ID, reporta únicamente los incidentes con heridos, muertos o daños superiores a 1.000 dólares, y se enlaza con la tabla de vehículos mediante ese mismo identificador. En la encuesta de pobreza, cada fila corresponde a una persona (identificada por la combinación del hogar y su orden dentro de este) y lleva asociado un peso muestral. Como la encuesta no consulta a toda la población, las cifras agregadas por persona, como la tasa de pobreza por distrito, deben calcularse ponderando por este peso y no mediante un conteo simple de filas. La suma de los pesos permite además estimar la población de cada distrito, con un total aproximado de 8,2 millones de habitantes. El perfil detallado de cada columna, con el

porcentaje de valores presentes y ejemplos representativos, se documenta en el repositorio del proyecto.

4. Exploración de los datos

El análisis exploratorio se realizó sobre la capa plata del clúster. Las comparaciones entre distritos se expresan en tasas por cada 100.000 habitantes y no en conteos absolutos, con el fin de no confundir el tamaño de la población con la intensidad del fenómeno. A continuación se resumen los ocho hallazgos principales del análisis.

En primer lugar, los arrestos cayeron en 2020 (año de la pandemia, con 140.413 casos) y aumentaron de forma sostenida hasta 278.953 en 2025, un 30% más que en 2019. (Ver Figura 1). Por otro lado, al comparar los distritos por tasa poblacional (Ver Figura 2), el Bronx (3.437 arrestos por 100.000 habitantes al año) y Manhattan (3.233) casi duplican a Queens y Staten Island (alrededor de 1.950); en el caso de Manhattan, la elevada tasa podría estar influida por su población flotante de trabajadores y visitantes, hipótesis que se profundizará en la entrega final. Además, entre el 40% y el 45% de los arrestos corresponden a felonías y entre el 52% y el 59% a delitos menores, con Brooklyn como el distrito de mayor proporción de felonías; los delitos más frecuentes son la agresión de menor gravedad (15,2%) y el hurto menor (9,9%). (Ver figura 3).

Figura 1

Arrestos por año, de 2019 al primer semestre del 2026.






Figura 2

Arrestos al año por cada 100.000 habitantes, promedio 2019–2025.

**Figura 3**

Composición de los arrestos de cada borough según la gravedad legal.



El total de choques se redujo un 60% entre 2019 y 2025, aunque los choques con heridos o muertos disminuyeron en menor proporción, por lo que su participación relativa aumentó; la causa de esta caída aún no se ha establecido con certeza. (Ver figura 4). También, en el mapa de calor de la Figura 5 se aprecia que los choques graves se concentran entre semana, en las horas de la tarde (2:00 p. m. a 6:00 p. m.), mientras que los fines de semana se distribuyen más hacia la noche y la madrugada. Este patrón resulta relevante para orientar el momento de las intervenciones viales.

Y otro aspecto bastante interesante es que entre el 31,7% (Manhattan) y el 35,5% (Brooklyn) de los choques dejan al menos una persona herida o fallecida, y la distracción del

conductor es, por amplio margen, la causa más frecuente (211.288 casos), aunque en el 24,6% de los registros la causa no se especifica. (Ver Figura 6 y 7).

Figura 4

Choques por mes: total y choques con heridos o muertos.




Figura 5

Choques con heridos o muertos por hora del día y día de la semana.




Figura 6

Porcentaje de choques con heridos o muertos en cada borough.





Figura 7


Los 10 factores contribuyentes más frecuentes.




En séptimo lugar, la tasa de pobreza por distrito va del 15,1% en Manhattan al 27,1% en el Bronx (Ver Figura 8), mientras que la proporción de adultos con título universitario va del 61% en Manhattan al 20% en el Bronx. (Ver Figura 9). Por último, al integrar los indicadores por distrito (tabla 4), el Bronx concentra simultáneamente la mayor pobreza, el menor nivel educativo y la mayor tasa de arrestos, mientras que Brooklyn presenta la mayor tasa de choques graves; esta coincidencia entre indicadores no implica una relación causal y se examinará con mayor detalle en la entrega final.

Figura 8

Tasa de pobreza por borough en 2018 (medida oficial de la ciudad), calculada con los pesos de la encuesta.

**Figura 9**

Nivel educativo de los adultos por borough, 2018.

**Tabla 4**

Indicadores por distrito (borough)

Distrito	Población	Pobreza	Con pregrado o	SAT total	Arrestos / 100 mil hab.	Choques graves / 100
----------	-----------	---------	----------------	-----------	-------------------------	----------------------

			más			mil hab.
Bronx	1.389.245	27,1 %	19,8 %	1.145	3.437	449
Brooklyn	2.540.638	20,3 %	37,6 %	1.167	2.270	491
Manhattan	1.568.288	15,1 %	60,9 %	1.260	3.233	381
Queens	2.250.749	17,0 %	32,1 %	1.275	1.969	464
Staten Island	469.393	16,0 %	32,5 %	1.359	1.935	360

Nota. Las tasas corresponden al promedio anual de 2019 a 2025. Población, pobreza y educación con datos de la encuesta de 2018, ponderados. Puntaje del SAT de 2012. Un choque se considera grave si registra al menos un herido o un fallecido.

5. Reporte de calidad de los datos

La evaluación de calidad consideró tanto los valores faltantes explícitos (casillas vacías o nulas) (Ver Figura 10) como los valores faltantes disfrazados, es decir, entradas que contienen un valor pero no aportan información real, como las coordenadas (0, 0) (ubicadas en el océano) o las categorías Unspecified y Unknown. La tabla 5 resume los resultados para las fuentes evaluadas dentro del periodo de estudio.


Tabla 5

Resumen de valores faltantes por fuente

Fuente	Filas evaluadas	Columnas con faltantes	Casillas faltantes	Columna más incompleta
Arrestos	1.608.509	7 de 18	0,05 %	Gravedad legal (0,70 %)
Choques	848.742	20 de 29	29,90 %	Tipo del 5.º vehículo (99,38 %)
Vehículos	1.715.328	19 de 25	22,83 %	Modelo del vehículo (99,45 %)
Pobreza	68.273	8 de 61	3,23 %	Dominio del inglés (55,01 %)
SAT	478	0 de 6	0,00 %	Ninguna (57 colegios con dato oculto)

Figura 10

Porcentaje de valores faltantes en cada columna de la tabla de choques.



Entre los hallazgos más relevantes se destaca la ausencia del distrito en el 31,8% de los choques, el problema de mayor impacto sobre el análisis por zona, dado que sin distrito casi un tercio de los registros quedaría excluido; de estos, 221.658 casos cuentan con coordenadas válidas y son recuperables mediante un cruce espacial. También se identificó que la columna de grupo de edad de los arrestos de 2025 presenta el valor nulo en el 52,8% de esos registros (frente al 0% en los demás años), lo que indica un cambio en el proceso de captura del dato y no un faltante aleatorio; por esta razón, 2025 se excluirá de las comparaciones por edad. Asimismo, la causa del choque no se especifica en el 24,6% de los casos, y columnas como el tercer al quinto vehículo involucrado presentan altos porcentajes de vacíos que corresponden a la naturaleza del dato (la mayoría de los choques involucra uno o dos vehículos) y no a errores de captura. En la encuesta de pobreza, los faltantes en variables como nivel educativo o estado civil corresponden a preguntas que no se formulan a ciertos rangos de edad.

Con base en estos hallazgos se definió un tratamiento diferenciado por problema: el distrito faltante en los choques se recupera mediante cruce espacial; las coordenadas en (0, 0) y los valores fuera de rango se dejan vacíos sin eliminar el registro; los códigos de gravedad no documentados se agrupan en una categoría explícita; y ningún valor se imputa arbitrariamente cuando ello pudiera introducir sesgos, como ocurre con la raza de la persona arrestada o la causa no especificada del choque, cuyo tratamiento definitivo se abordará posteriormente.

6. Planteamiento de preguntas de negocio

1. ¿Cuál es la tasa de arrestos por cada 100.000 habitantes en cada distrito y en cada barrio, y cómo ha cambiado entre 2019 y 2026?
2. ¿Los distritos con mayor tasa de pobreza presentan también una mayor tasa de arrestos por habitante, y esta relación se mantiene al separar felonías de delitos menores?
3. ¿Qué tipos de delito predominan en los distritos con mayor pobreza frente a los de menor pobreza?
4. ¿Cuáles son los diez barrios con mayor tasa de choques con heridos o muertos?
5. ¿Qué causas del choque y qué tipos de vehículo se asocian con una mayor proporción de choques con heridos o muertos?
6. ¿En qué horas y días se concentran los choques graves, y este patrón es homogéneo entre distritos?
7. ¿Qué barrios combinan una alta tasa de arrestos con una alta tasa de choques graves y deberían priorizarse?
8. ¿Los arrestos por infracciones de tránsito y conducción bajo estado de embriaguez se concentran en las zonas con mayor accidentalidad grave?

7. Filtros, limpieza y transformación inicial

La capa plata del proyecto se construyó mediante los siguientes procedimientos, cuyo efecto se midió en cada caso: unificación de los arrestos históricos con los del año en curso; filtro del periodo de estudio (arrestos hasta el 30 de junio de 2026, y choques y vehículos hasta el 31 de mayo de 2026, último mes con datos completos); asignación del tipo de dato correcto a cada columna; conversión a valores vacíos de los datos imposibles, como coordenadas fuera de Nueva York o años de fabricación inválidos; traducción de los códigos oficiales a su descripción; y un cruce espacial que ubica cada arresto y cada choque dentro de su barrio a partir de sus coordenadas.

Tabla 6

Registros antes y después del filtro de periodo

Fuente	Registros originales	En el periodo de estudio
Arrestos	6.406.848	1.608.509
Choques	2.269.187	846.420
Vehículos	4.551.002	1.710.836

No se encontraron registros duplicados en ninguna de las tres fuentes. El cruce espacial permitió recuperar el distrito de 219.488 choques que no lo tenían registrado (25,9% del total) a partir de sus coordenadas; validado contra los registros que sí contaban con ambos datos, la coincidencia entre el distrito original y el obtenido por cruce espacial alcanzó el 99,88% en choques y el 99,7% en arrestos, lo que respalda la confiabilidad del método. Como resultado, el

94,1% de los choques cuenta hoy con distrito asignado, frente al 68,2% con que se contaba originalmente.

Para efectos del trabajo futuro, queda pendiente completar los conteos de víctimas, unificar las categorías de tipo de vehículo y de causa del choque, definir el tratamiento de la edad en los arrestos de 2025, y construir la capa oro con los resúmenes que alimentarán el modelo de clasificación y la segmentación de barrios.

8. Bono: extracción de datos web (web scraping)

Como complemento, la población oficial de cada distrito se obtuvo mediante web scraping, es decir, la extracción automatizada de datos a partir del código HTML de una página web, técnica que se emplea cuando la información se publica únicamente para ser consultada en el navegador, sin archivo descargable ni API. La fuente es la tabla 2 de las estadísticas vitales del estado de Nueva York de 2018 (New York State Department of Health, 2020), que reporta para los 62 condados del estado la población estimada de 2018, la del censo de 2010, el área y la densidad; en Nueva York cada distrito corresponde a un condado (Kings equivale a Brooklyn, New York a Manhattan y Richmond a Staten Island). A diferencia de la encuesta de pobreza, que excluye a quienes residen en alojamientos colectivos, esta cifra incluye a toda la población residente, por lo que constituye un mejor denominador para las tasas por habitante.

El proceso se automatizó en el notebook 06_bono_scraping_poblacion. Se llevó a cabo un registro de la huella SHA-256 del archivo y copia en la capa cruda de HDFS, recorrido de la tabla fila por fila con la librería BeautifulSoup (distinguiendo los títulos de sección de las filas de datos), limpieza de los valores numéricos y validación. Esta última se apoyó en los totales publicados por la propia tabla, así que se verificó que existieran 62 condados, que los cinco distritos sumaran exactamente el total de la ciudad en 2018 y en 2010, que los 62 condados sumaran el total del estado y que la densidad publicada coincidiera con la población dividida por el área, con la misma precisión de dos decimales de la fuente. Las siete validaciones se cumplieron, y la tabla 7 resume los datos obtenidos para los cinco distritos.

Tabla 7

Población oficial, área y densidad por distrito, 2018

Distrito (condado)	Población 2018	Población 2010	Área (km ²)	Habitantes por km ²
Bronx (Bronx)	1.432.132	1.385.108	109,0	13.139
Brooklyn (Kings)	2.582.830	2.504.700	183,4	14.083
Manhattan (New York)	1.628.701	1.585.873	59,1	27.558


Queens (Queens)	2.278.906	2.230.722	281,1	8.107
Staten Island (Richmond)	476.179	468.730	151,2	3.149
Nueva York	8.398.748	8.175.133	783,9	10.715

Nota. Datos extraídos mediante web scraping de New York State Department of Health (2020). El área se convirtió de millas cuadradas a kilómetros cuadrados ($1 \text{ mi}^2 = 2,59 \text{ km}^2$).

Manhattan alcanza 27.558 habitantes por km^2 , casi el doble que Brooklyn (14.083) y el Bronx (13.139) y cerca de nueve veces la densidad de Staten Island (3.149) (ver Figura 11), un factor relevante para interpretar la accidentalidad, pues una mayor densidad implica más peatones, vehículos y cruces por calle. Por su parte, la población estimada con la encuesta (tabla 4) resulta inferior a la oficial en todos los distritos, entre el 1,2% (Queens) y el 3,7% (Manhattan), con una diferencia total de 180.435 personas (2,1%), compatible con la exclusión de los alojamientos colectivos, aunque los datos disponibles no permiten comprobarlo.

Figura 11

Densidad de población por distrito, 2018 (habitantes por km^2).



Fuente: NYS Department of Health, Vital Statistics 2018, Tabla 2 (scraping propio).

Finalmente, se recalcularon las tasas por cada 100.000 habitantes con la población oficial (tabla 8). Las tasas disminuyen entre el 1,3% y el 3,7%, sin que ningún distrito cambie de posición: el Bronx mantiene la mayor tasa de arrestos (3.334) y Brooklyn la mayor tasa de choques graves (483). En consecuencia, los hallazgos de la exploración no dependen de la población utilizada, y se propone emplear la cifra oficial como denominador en la entrega final.

La principal limitación de esta fuente es que reporta los datos por condado, de modo que la población por barrio continúa sin estar disponible.

Tabla 8

Tasas anuales por cada 100.000 habitantes según la población utilizada

Distrito	Arrestos (encuesta)	Arrestos (oficial)	Choques graves (encuesta)	Choques graves (oficial)
Bronx	3.437	3.334	449	436
Brooklyn	2.270	2.233	491	483
Manhattan	3.233	3.113	381	367
Queens	1.969	1.944	464	458
Staten Island	1.935	1.908	360	354

Nota. Promedio anual de 2019 a 2025. Los valores calculados con la población de la encuesta corresponden a los de la tabla 4. Un choque se considera grave si registra al menos un herido o un fallecido.

Anexo

El código, los notebooks ejecutados y la documentación técnica de la infraestructura empleada en esta entrega se encuentran disponibles en el repositorio del proyecto: <https://github.com/MateoJara/proyecto-nyc-bigdata>.

Referencias

- New York City Department of City Planning. (2025). New York City's population estimates and trends, May 2025 release (Census Bureau vintage 2024). https://www.nyc.gov/assets/planning/downloads/pdf/our-work/reports/new-york-city-population-estimates-and-trends_may-2025.pdf
- New York City Department of Transportation. (2026). Traffic deaths reach all-time low: New York ends year with fewest fatalities ever recorded. <https://www.nyc.gov/html/dot/html/pr2026/traffic-deaths-reach-all-time-low.shtml>
- New York City Mayor's Office for Economic Opportunity. (s. f.). NYCgov poverty measure data dictionary [Documento anexo al conjunto de datos]. NYC Open Data.
- New York City Open Data. (s. f.-a). Motor vehicle collisions – Crashes [Conjunto de datos]. https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Crashes/h9gi-nx95/about_data

- New York City Open Data. (s. f.-b). Motor vehicle collisions – Vehicles [Conjunto de datos]. https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Vehicles/bm4k-52h4/about_data
- New York City Open Data. (s. f.-c). NYPD arrests data (historic) [Conjunto de datos]. https://data.cityofnewyork.us/Public-Safety/NYPD-Arrests-Data-Historic-/8h9b-rp9u/about_data
- New York City Open Data. (s. f.-d). NYPD arrest data (year to date) [Conjunto de datos]. https://data.cityofnewyork.us/Public-Safety/NYPD-Arrest-Data-Year-to-Date-/uip8-fykc/about_data
- New York City Open Data. (s. f.-e). 2010 Public use microdata areas (PUMAs) [Conjunto de datos]. https://data.cityofnewyork.us/City-Government/2010-Public-Use-Microdata-Areas-PUMAs-/k2r4-n9ax/about_data
- New York City Open Data. (s. f.-f). 2012 SAT results [Conjunto de datos]. https://data.cityofnewyork.us/Education/2012-SAT-Results/f9bf-2cp4/about_data
- New York State Department of Health. (2020). Table 2: Population, land area, and population density by county, New York State - 2018. En Vital statistics of New York State 2018. https://www.health.ny.gov/statistics/vital_statistics/2018/table02.htm
- New York State Department of Labor. (s. f.). Developments in the New York City labor market. <https://dol.ny.gov/labor-statistics-new-york-city-region>
- Robin Hood, & Columbia University. (2024). The state of poverty and disadvantage in New York City (Poverty Tracker, Annual Report 2024). <https://robinhood.org/wp-content/uploads/2024/02/Annual-Poverty-Tracker-Report-2024.pdf>
- The Apache Software Foundation. (s. f.-a). Apache Spark 4.1.3 documentation. <https://spark.apache.org>
- The Apache Software Foundation. (s. f.-b). Apache Hadoop 3.5.0 documentation. <https://hadoop.apache.org>
- U.S. Bureau of Economic Analysis. (s. f.). Total gross domestic product for New York-Newark-Jersey City, NY-NJ-PA (MSA) [Serie de datos NGMP35620]. FRED, Federal Reserve Bank of St. Louis. <https://fred.stlouisfed.org/series/NGMP35620>
- U.S. Bureau of Labor Statistics. (2025). Alternative measures of labor underutilization in New York — 2025. https://www.bls.gov/regions/northeast/news-release/laborunderutilization_new_york.htm